

Análisis de importancia de variables con modelos de aprendizaje de máquina para la agresión física en la adultez joven

Jerónimo Deli Larios y Juan Pablo Cordero Mayorga

2026-05-25

Abstract

En este trabajo estudiamos si la información observada durante la adolescencia ayuda a anticipar la agresión física en la adultez joven. Usamos la Encuesta Nacional Longitudinal de la Juventud de 1997, en su versión ICPSR 34562, y construimos una variable que identifica si una persona reportó haber agredido físicamente a alguien entre los 18 y los 23 años. A partir de variables medidas entre los 14 y los 17 años, estimamos bosques aleatorios, comparamos la importancia de variables y usamos componentes principales como apoyo descriptivo. Encontramos que la agresión temprana es el predictor más fuerte de la agresión posterior y que las conductas de riesgo tienden a agruparse en una misma dimensión. Al separar inicio y persistencia, observamos que el inicio es más predecible que la continuidad de la violencia. Estos resultados apoyan una política de prevención temprana y prudente en el uso de modelos de riesgo.

1 Mérito intelectual del proyecto

La violencia juvenil nos parece un problema importante de política pública porque no termina en el momento del acto violento. Afecta a las víctimas, a las familias, a las escuelas y también a las trayectorias de quienes la ejercen. La literatura de criminología del curso de vida ha documentado que la conducta antisocial tiende a ser estable en el tiempo, aunque no todas las personas que tienen conductas violentas en la adolescencia las mantienen en la adultez (Moffitt 1993; Sampson y Laub 1993). Desde ahí surge una pregunta que nos interesa como estudiantes de Ciencia de Datos: qué tanto se puede anticipar la violencia posterior usando información observada antes de que ocurra.

Esta pregunta se conecta con dos explicaciones clásicas. Gottfredson y Hirschi (1990) argumentan que ciertas conductas problemáticas comparten un origen común asociado con bajo autocontrol, mientras que Hirschi (1969) enfatiza la importancia de los vínculos sociales con la familia, la escuela y otras instituciones. En términos de política pública, la diferencia no es menor. Si la violencia posterior se explica sobre todo por rasgos estables, entonces la conducta previa debería pesar mucho en cualquier predicción. Si, en cambio, el entorno social modifica las trayectorias, entonces las condiciones familiares, escolares y económicas deberían ayudar a identificar momentos de intervención.

Nuestro trabajo parte de dos preguntas. Primero, queremos saber qué variables de la adolescencia predicen mejor la agresión física entre los 18 y los 23 años. Segundo, queremos distinguir si los factores asociados con empezar a agredir son los mismos que se relacionan con seguir agrediendo. Esta separación es central para la discusión pública, porque no es lo mismo diseñar programas universales de prevención que decidir a quién se le da seguimiento después de un primer episodio de violencia.

La contribución que buscamos hacer es combinar una pregunta sustantiva de política pública con herramientas predictivas. Usamos bosques aleatorios e importancia de variables sobre una cohorte nacional de Estados Unidos, en lugar de trabajar con una muestra clínica o local. Además, usamos análisis de componentes principales para describir si las distintas conductas de riesgo se agrupan en una dimensión común. Con esto dialogamos con la síntesis de predictores de violencia juvenil de Lipsey y Derzon (1998) y con la discusión sobre heterogeneidad poblacional y dependencia de

estado planteada por Nagin y Paternoster (1991). Todo el análisis se apoya en fuentes académicas y en datos documentados por el Bureau of Justice Statistics y el ICPSR (United States Department of Justice, Office of Justice Programs, Bureau of Justice Statistics 2014).

2 Variables y datos

Usamos el estudio ICPSR 34562, preparado por el Bureau of Justice Statistics con base en la Encuesta Nacional Longitudinal de la Juventud de 1997, conocida como NLSY97 (United States Department of Justice, Office of Justice Programs, Bureau of Justice Statistics 2014). Esta encuesta siguió a 8,984 personas nacidas en Estados Unidos entre 1980 y 1984. Para nuestro objetivo, la ventaja principal de la base es que permite observar información de la adolescencia y después relacionarla con resultados en la adultez joven. Una característica importante del archivo es que muchas variables están organizadas por edad y no por año calendario. Esto importa porque las edades más tempranas tienen mejor cobertura entre quienes eran más jóvenes cuando empezó la encuesta.

La variable dependiente principal toma el valor de uno si la persona reportó haber agredido físicamente a alguien con intención de hacerle daño en al menos una ocasión entre los 18 y los 23 años, y toma el valor de cero en caso contrario. Elegimos esa ventana porque tiene una cobertura adecuada en la encuesta y porque evita usar los datos de los 24 y 25 años, que provienen de una submuestra de personas en prisión y podrían elevar artificialmente la prevalencia de violencia. De las 8,984 personas en la muestra original, 8,609 tienen al menos una respuesta válida para esta variable. Dentro de ese grupo, 16.9 por ciento reportó haber agredido a alguien entre los 18 y los 23 años.

Todas las variables explicativas fueron medidas antes del periodo que queremos predecir. Algunas vienen del levantamiento inicial de 1997 y otras resumen conductas observadas entre los 14 y los 17 años. Esta decisión es importante porque evita usar información contemporánea al resultado. En la parte de contexto incluimos sexo, raza o etnicidad, estructura familiar, escolaridad y empleo de los padres, número de hermanos, razón entre ingreso del hogar y línea de pobreza, edad de la madre al nacimiento y puntaje ASVAB, que usamos como aproximación a habilidades cognitivas. En la parte de conductas adolescentes incluimos agresión, destrucción de propiedad, robo, venta de drogas, portación de arma, pertenencia a pandillas, consumo de alcohol, tabaco, marihuana y drogas duras, además de arresto o encarcelamiento antes de los 17 años. La Figura 1 del anexo muestra la

relación entre edad y agresión en estos datos, con un aumento durante la adolescencia y una caída posterior, como plantea la literatura sobre edad y crimen (Hirschi y Gottfredson 1983).

Como suele ocurrir en encuestas longitudinales, la base tiene datos faltantes. Esto se debe tanto a la estructura por edad del archivo como a la pérdida de seguimiento de algunas personas. En el procesamiento tratamos los códigos especiales de la NLSY97 como valores faltantes y, para poder estimar los modelos con una matriz completa, imputamos las variables explicativas con su mediana. Esta decisión es práctica, pero también tiene límites. Algunas variables, como el ingreso del hogar o el empleo del padre, tienen menor cobertura que otras, por lo que su importancia debe leerse con cautela.

3 Diseño empírico general

El diseño empírico es predictivo, no causal. Por eso, no interpretamos los resultados como efectos de una variable sobre la violencia, sino como evidencia sobre qué información ayuda más a anticiparla. El modelo principal es un bosque aleatorio, que combina muchos árboles de decisión estimados sobre muestras distintas de los datos y con subconjuntos aleatorios de variables en cada partición (Breiman 2001). La predicción final se obtiene promediando las predicciones de todos los árboles. En términos formales, la probabilidad estimada para una persona con características x es $\hat{p}(x) = \frac{1}{B} \sum_{b=1}^B \hat{p}_b(x)$, donde B es el número de árboles y $\hat{p}_b(x)$ es la proporción de casos violentos en la hoja a la que llega esa persona en el árbol b .

Para decidir las particiones, cada árbol busca separar los datos en grupos cada vez más homogéneos. La medida que usa el algoritmo es el índice de Gini, $G = 1 - \sum_k p_k^2$, donde p_k representa la proporción de la clase k dentro de un nodo. A partir de ese criterio calculamos una primera medida de importancia de variables: cuánto reduce cada variable la impureza del modelo, acumulado a lo largo de los árboles. Esta medida es útil, pero puede favorecer variables con muchos valores posibles (Strobl et al. 2007). Por esa razón también usamos importancia por permutación. La lógica es sencilla: si una variable contiene información relevante, mezclar sus valores al azar debería empeorar el desempeño del modelo. La expresamos como $PI_j = A - \frac{1}{R} \sum_{r=1}^R A_{\pi_j^{(r)}}$, donde A es el área bajo la curva ROC original y $A_{\pi_j^{(r)}}$ es el área obtenida después de permutar la variable j en la repetición r .

Para evaluar el desempeño, separamos 20 por ciento de los datos como muestra de prueba y entrenamos el modelo con el 80 por ciento restante. Además, usamos validación cruzada de cinco pliegues. En ambos casos reportamos el área bajo la curva ROC, que puede interpretarse como la probabilidad de que el modelo asigne un riesgo mayor a una persona que sí reportó agresión que a una persona que no la reportó. Como la agresión física entre los 18 y los 23 años es un evento minoritario, usamos pesos inversos a la frecuencia de cada clase para que el modelo no aprenda a favorecer sistemáticamente la categoría más común.

También usamos análisis de componentes principales como ejercicio descriptivo. Estandarizamos las variables de conducta y algunas variables socioeconómicas para analizar si las conductas

de riesgo se mueven juntas. El primer componente es la combinación lineal que maximiza la varianza, $w_1 = \arg \max_{\|w\|=1} \text{Var}(Xw)$, y los siguientes componentes corresponden a direcciones ortogonales con menor varianza explicada. No usamos este ejercicio para hacer predicción individual, sino para interpretar si existe una dimensión común detrás de las conductas adolescentes.

Estimamos tres modelos. El primero usa toda la muestra modelable y todas las variables medidas antes de los 18 años. Los otros dos separan a las personas según si reportaron agresión entre los 14 y los 17 años. En esos modelos quitamos la agresión temprana como predictor, porque ya se usa para definir el grupo. El modelo de inicio incluye a quienes no habían reportado agresión temprana y pregunta qué predice que empiecen a agredir en la adultez joven. El modelo de persistencia incluye a quienes sí habían reportado agresión temprana y pregunta qué predice que continúen. Nuestra expectativa era que la agresión temprana pesara mucho en el modelo global y que los modelos de inicio y persistencia mostraran patrones distintos.

4 Resultados

El primer resultado es que la agresión temprana concentra gran parte de la información predictiva. Como se observa en la Tabla 2 y en la Figura 2 del anexo, es la variable más importante tanto por reducción de impureza como por permutación. La diferencia descriptiva también es clara: entre quienes reportaron agresión entre los 14 y los 17 años, 37.4 por ciento volvió a reportarla entre los 18 y los 23 años. Entre quienes no habían reportado agresión temprana, la proporción fue de 10.6 por ciento. El modelo global obtuvo un área bajo la curva de 0.80 en la muestra de prueba y de 0.76 en validación cruzada. Después de la agresión temprana aparecen, con menor peso, habilidad cognitiva, ingreso del hogar, venta temprana de drogas, sexo y pertenencia a pandillas.

El análisis de componentes principales aporta una lectura complementaria. La Figura 3 muestra que el primer componente explica cerca de 20 por ciento de la varianza y carga positivamente sobre distintas conductas antisociales y de riesgo, como vender drogas, consumir marihuana, destruir propiedad, robar, agredir o portar un arma. Ese componente se correlaciona en 0.30 con la agresión adulta. Para nosotros, esto sugiere que las conductas adolescentes no deben leerse como hechos completamente aislados. Más bien, parecen formar un patrón común, consistente con la idea de conducta problema de Jessor y Jessor (1977) y con la teoría general del crimen de Gottfredson y Hirschi (1990).

El resultado más importante aparece al separar inicio y persistencia. Entre las 6,568 personas que no habían agredido entre los 14 y los 17 años, el modelo de inicio obtuvo un área bajo la curva de 0.71. Las variables más relevantes combinan características individuales, entorno y conductas tempranas de riesgo: habilidad cognitiva, edad de la madre al nacimiento, pertenencia a pandillas, ingreso del hogar, consumo de alcohol, sexo y razón de pobreza. En cambio, entre las 2,029 personas que ya habían reportado agresión temprana, el modelo de persistencia tuvo un área bajo la curva de 0.58 en la muestra de prueba. Esto significa que, con las variables disponibles, distinguir quién continuará agrediendo es mucho más difícil que distinguir quién podría iniciar.

En el modelo de persistencia, las señales que aparecen son más débiles y menos estables. La razón de pobreza, la habilidad cognitiva, el ingreso del hogar, la edad de la madre, la venta temprana de drogas, la portación de arma y el arresto antes de los 17 años aparecen entre las variables con mayor

importancia de Gini. Sin embargo, el desempeño general del modelo nos obliga a ser cuidadosos: esas variables no bastan para generar una predicción fuerte. Este punto es relevante para política pública, porque muestra que haber observado violencia temprana no permite clasificar con precisión quién seguirá una trayectoria violenta.

Los contrastes bivariados de la Tabla 4 son consistentes con la literatura. La tasa de agresión adulta fue mayor entre hombres que entre mujeres, 21.7 frente a 11.9 por ciento. También fue mayor en personas que crecieron en estructuras familiares distintas a dos padres biológicos, lo que coincide con la evidencia revisada por Loeber y Stouthamer-Loeber (1986) sobre factores familiares. Aun así, en los modelos predictivos algunas de estas variables quedan por debajo de conductas tempranas más directas. Nuestra interpretación es que parte de la relación entre contexto familiar y violencia posterior puede operar a través de las conductas adolescentes, una idea compatible con el enfoque de curso de vida de Sampson y Laub (1993).

5 Conclusión

Nuestro principal hallazgo es que la agresión temprana es el predictor más fuerte de la agresión física en la adultez joven. Esto confirma, con una estrategia predictiva y una cohorte nacional, una idea central de la criminología del desarrollo: las conductas antisociales muestran continuidad en el tiempo (Farrington 2003; Moffitt 1993). Sin embargo, creemos que la aportación más importante del trabajo está en separar el inicio de la persistencia. El inicio de la agresión se puede anticipar con un desempeño razonable a partir de variables observadas en la adolescencia, mientras que la persistencia es mucho más difícil de predecir con la información disponible.

La implicación de política pública es que la prevención temprana parece más prometedora que la clasificación individual de jóvenes como casos de alto riesgo. Si variables como consumo temprano de alcohol, pertenencia a pandillas, habilidad cognitiva, ingreso del hogar y pobreza ayudan a anticipar el inicio, entonces las intervenciones amplias en entornos vulnerables tienen sentido. Esta lectura es consistente con la evidencia de Heckman (2006) sobre la importancia de invertir temprano en poblaciones desfavorecidas. Al mismo tiempo, el bajo desempeño del modelo de persistencia sugiere que las herramientas actuariales deben usarse con mucha prudencia, porque una predicción débil puede generar errores costosos para personas concretas.

El trabajo también tiene límites. La agresión está medida por autorreporte y no distingue entre distintos niveles de gravedad. Además, algunas variables tienen cobertura parcial y fueron imputadas con la mediana, lo cual puede reducir o distorsionar su importancia. Por último, la cohorte corresponde a jóvenes nacidos en Estados Unidos entre 1980 y 1984, por lo que cualquier lectura para México debe hacerse con cuidado. Aun con estas limitaciones, el resultado central se mantiene: prevenir el inicio de la violencia parece una meta más alcanzable que predecir su persistencia, y esto debería orientar la forma en que se diseñan y evalúan las políticas públicas sobre violencia juvenil.

6 Anexo: tablas y figuras

Tabla 1: Desempeño de los tres modelos de bosque aleatorio.

Modelo	Muestra	Prevalencia	AUC prueba	AUC validación cruzada
Global (14-17 a 18-23)	8,609	16.9 %	0.80	0.76 (± 0.03)
Inicio (sin agresión temprana)	6,568	10.6 %	0.71	0.70 (± 0.04)
Persistencia (con agresión temprana)	2,029	37.4 %	0.58	0.62 (± 0.04)

Tabla 2: Importancia de variables en el modelo global.

Variable	Importancia de Gini	Importancia por permutación
Agresión temprana (14-17)	0.228	0.079
Habilidad cognitiva (ASVAB)	0.080	0.007
Ingreso del hogar (14-17)	0.064	bajo
Venta de drogas temprana	0.059	0.003
Razón de pobreza (1997)	0.055	bajo
Edad de la madre al nacer	0.055	0.005
Destrucción de propiedad temprana	0.053	0.003
Sexo (hombre)	0.049	0.014
Pandilla temprana	0.044	0.010
Alcohol temprano	0.041	0.014

Tabla 3: Importancia de Gini en los modelos de inicio y persistencia.

Modelo de inicio	Importancia	Modelo de persistencia	Importancia
Habilidad cognitiva	0.142	Razón de pobreza	0.116
Edad de la madre	0.091	Habilidad cognitiva	0.098
Pandilla temprana	0.087	Ingreso del hogar	0.098
Ingreso del hogar	0.084	Edad de la madre	0.091
Alcohol temprano	0.081	Venta de drogas temprana	0.084
Sexo (hombre)	0.079	Portación de arma temprana	0.055
Razón de pobreza	0.075	Arresto antes de los 17	0.046

Tabla 4: Tasas de agresión adulta por subgrupo.

Grupo	Categoría	Tasa de agresión 18-23
Sexo	Hombre	21.7 %
Sexo	Mujer	11.9 %
Raza o etnicidad	Afroamericano	21.5 %
Raza o etnicidad	Hispano	16.8 %
Raza o etnicidad	Blanco u otro	14.5 %
Estructura familiar	Dos padres biológicos	13.5 %
Estructura familiar	Un solo padre	18.4 %
Estructura familiar	Otra estructura	22.9 %




Figura 1: Curva edad-agresión en la NLSY97. La prevalencia del autorreporte de agresión asciende en la adolescencia media y desciende en la adultez joven, replicando el patrón clásico edad-crimen.




Figura 2: Importancia de variables en el modelo global de bosque aleatorio. La agresión temprana domina sobre todas las demás variables.




Figura 3: Análisis de componentes principales de los factores de riesgo medidos entre los 14 y 17 años. El primer componente carga sobre todas las conductas antisociales a la vez, lo que evidencia un factor general de delincuencia.




Figura 4: Importancia de variables en el modelo de inicio. Los predictores son marcadores del contexto social, no señales criminales.




Figura 5: Importancia de variables en el modelo de persistencia. La capacidad predictiva es baja y solo asoman, de forma débil, la desventaja socioeconómica y el arraigo delictivo.

Referencias

- Breiman, Leo. 2001. «Random Forests». *Machine Learning* 45(1): 5-32.
- Farrington, David P. 2003. «Developmental and Life-Course Criminology: Key Theoretical and Empirical Issues». *Criminology* 41(2): 221-55.
- Gottfredson, Michael R., y Travis Hirschi. 1990. *A General Theory of Crime*. Stanford, CA: Stanford University Press.
- Heckman, James J. 2006. «Skill Formation and the Economics of Investing in Disadvantaged Children». *Science* 312(5782): 1900-1902.
- Hirschi, Travis. 1969. *Causes of Delinquency*. Berkeley: University of California Press.
- Hirschi, Travis, y Michael Gottfredson. 1983. «Age and the Explanation of Crime». *American Journal of Sociology* 89(3): 552-84.
- Jessor, Richard, y Shirley L. Jessor. 1977. *Problem Behavior and Psychosocial Development: A Longitudinal Study of Youth*. New York: Academic Press.
- Lipsey, Mark W., y James H. Derzon. 1998. «Predictors of Violent or Serious Delinquency in Adolescence and Early Adulthood: A Synthesis of Longitudinal Research». En *Serious and Violent Juvenile Offenders: Risk Factors and Successful Interventions*, eds. Rolf Loeber y David P. Farrington. Thousand Oaks, CA: Sage, 86-105.
- Loeber, Rolf, y Magda Stouthamer-Loeber. 1986. «Family Factors as Correlates and Predictors of Juvenile Conduct Problems and Delinquency». *Crime and Justice* 7: 29-149.

- Moffitt, Terrie E. 1993. «Adolescence-Limited and Life-Course-Persistent Antisocial Behavior: A Developmental Taxonomy». *Psychological Review* 100(4): 674-701.
- Nagin, Daniel S., y Raymond Paternoster. 1991. «On the Relationship of Past to Future Participation in Delinquency». *Criminology* 29(2): 163-89.
- Sampson, Robert J., y John H. Laub. 1993. *Crime in the Making: Pathways and Turning Points Through Life*. Cambridge, MA: Harvard University Press.
- Strobl, Carolin, Anne-Laure Boulesteix, Achim Zeileis, y Torsten Hothorn. 2007. «Bias in Random Forest Variable Importance Measures: Illustrations, Sources and a Solution». *BMC Bioinformatics* 8: 25.
- United States Department of Justice, Office of Justice Programs, Bureau of Justice Statistics. 2014. «Recidivism in the National Longitudinal Survey of Youth 1997 - Standalone Data (Rounds 1 to 13)». doi:[10.3886/ICPSR34562.v1](https://doi.org/10.3886/ICPSR34562.v1).