

Análisis de importancia de variables con modelos de aprendizaje de máquina para la agresión física en la adultez joven

Jerónimo Deli Larios y Juan Pablo Cordero Mayorga

2026-05-25

Abstract

En este trabajo analizamos si lo que ocurre durante la adolescencia ayuda a predecir la agresión física en la adultez joven. Usamos la Encuesta Nacional Longitudinal de la Juventud de 1997, que siguió a casi nueve mil jóvenes en Estados Unidos. Nuestra variable principal identifica si una persona reportó haber agredido físicamente a alguien entre los 18 y los 23 años. Con información medida entre los 14 y los 17 años, estimamos modelos de *random forest* y revisamos qué variables aportan más a la predicción. También separamos a quienes ya habían reportado agresión en la adolescencia de quienes no lo habían hecho. Encontramos que la agresión temprana es el predictor más importante. Además, el inicio de la agresión se puede anticipar mejor que su persistencia. Esto sugiere que la prevención temprana es más útil que intentar clasificar con precisión quién seguirá agrediendo.

1 Mérito intelectual del proyecto

La violencia juvenil nos parece un problema importante de política pública porque no termina en el momento del acto violento. Afecta a las víctimas, a las familias, a las escuelas y también a las oportunidades futuras de quienes la ejercen. Varios estudios han encontrado que las conductas antisociales en edades tempranas pueden repetirse más adelante, aunque esto no significa que todas las personas que agreden en la adolescencia necesariamente lo hagan en la adultez (Moffitt 1993; Sampson y Laub 1993). Desde ahí surge una pregunta que nos interesa como estudiantes de Ciencia de Datos: qué tanto se puede anticipar la agresión física posterior usando información observada antes de que ocurra.

La literatura ofrece dos formas sencillas de pensar este problema. Una dice que algunas personas son más propensas a involucrarse en distintas conductas de riesgo porque tienen menos autocontrol, por lo que la agresión temprana debería ayudarnos a predecir la agresión posterior (Gottfredson y Hirschi 1990). La otra dice que el entorno también importa: cuando una persona tiene vínculos más débiles con su familia, su escuela o su comunidad, es más probable que se acerque a conductas problemáticas (Hirschi 1969). Para política pública, esto cambia la forma de intervenir. Si lo más importante es la conducta previa, habría que poner atención en quienes ya reportaron agresión. Si el entorno también pesa, entonces tiene sentido intervenir antes, en las condiciones familiares, escolares y económicas que rodean a los jóvenes.

Nuestro trabajo parte de dos preguntas. Primero, queremos saber qué variables de la adolescencia predicen mejor la agresión física entre los 18 y los 23 años. Segundo, queremos distinguir si los factores asociados con empezar a agredir son los mismos que se relacionan con seguir agrediendo. Esta separación es central para la discusión pública, porque no es lo mismo diseñar programas universales de prevención que decidir a quién se le da seguimiento después de un primer episodio de violencia.

La contribución que buscamos hacer es combinar una pregunta sustantiva de política pública con herramientas predictivas. Usamos *random forest*, midiendo la importancia de variables. Además, utilizamos un análisis de componentes principales para describir si las distintas conductas de riesgo se agrupan en una dimensión común. Nuestro análisis retoma la literatura sobre predictores de

violencia juvenil de Lipsey y Derzon (1998) y la discusión de Nagin y Paternoster (1991) sobre si la conducta pasada predice la conducta futura porque las personas son distintas desde el inicio o porque una conducta previa cambia la trayectoria posterior.

2 Variables y datos

Usamos los datos del estudio ICPSR 34562, preparado por el Bureau of Justice Statistics con base en la Encuesta Nacional Longitudinal de la Juventud de 1997, conocida como NLSY97 (United States Department of Justice, Office of Justice Programs, Bureau of Justice Statistics 2014). Esta encuesta siguió a 8,984 personas nacidas en Estados Unidos entre 1980 y 1984. Para nuestro objetivo, la ventaja principal de la base es que permite seguir a las mismas personas durante varios años y comparar lo que reportaron en distintas etapas. En la base, varias preguntas no están guardadas por año de entrevista, sino por la edad de la persona cuando respondió. Por ejemplo, una columna puede resumir qué ocurrió a los 14 años y otra qué ocurrió a los 15. Esto hace que algunas edades tengan más información que otras, porque no todos los entrevistados tenían la misma edad cuando empezó la encuesta en 1997.

La variable dependiente principal toma el valor de uno si la persona reportó haber agredido físicamente a alguien con intención de hacerle daño en al menos una ocasión entre los 18 y los 23 años, y toma el valor de cero en caso contrario. La encuesta también tiene información para algunas edades posteriores, pero decidimos no usar los datos de los 24 y 25 años porque en esa parte aparecen observaciones de una submuestra de personas en prisión. Si las incluyéramos, la proporción de agresión podría verse más alta de lo que realmente es para la cohorte completa. De las 8,984 personas en la muestra original, 8,609 tienen al menos una respuesta válida para esta variable. Dentro de ese grupo, 16.9 por ciento reportó haber agredido a alguien entre los 18 y los 23 años.

Todas las variables explicativas fueron medidas antes del periodo que queremos predecir. Algunas vienen del levantamiento inicial de 1997 y otras resumen conductas observadas entre los 14 y los 17 años. Esta decisión es importante porque evita usar información contemporánea al resultado. En la parte de contexto incluimos sexo, raza o etnicidad, estructura familiar, escolaridad y empleo de los padres, número de hermanos, razón entre ingreso del hogar y línea de pobreza, edad de la madre al nacimiento y puntaje ASVAB. El ASVAB es una prueba de aptitudes usada en Estados Unidos que mide habilidades en áreas como razonamiento, matemáticas y comprensión verbal, por lo que la usamos como una aproximación a habilidades cognitivas. En la parte de conductas

adolescentes incluimos agresión, destrucción de propiedad, robo, venta de drogas, portación de arma, pertenencia a pandillas, consumo de alcohol, tabaco, marihuana y drogas duras, además de arresto o encarcelamiento antes de los 17 años. La Figura 1 del anexo muestra la relación entre edad y agresión en estos datos, con un aumento durante la adolescencia y una caída posterior, como plantea la literatura sobre edad y crimen (Hirschi y Gottfredson 1983).

Como suele ocurrir en encuestas longitudinales, la base tiene datos faltantes. Esto se debe tanto a la estructura por edad del archivo como a la pérdida de seguimiento de algunas personas. Además, la NLSY97 usa códigos especiales para distinguir respuestas como no sabe, no contestó, entrevista no realizada o pregunta no aplicable. En nuestro procesamiento tratamos esos códigos como valores faltantes, porque no representan una respuesta sustantiva. Para poder estimar los modelos con una matriz completa, imputamos las variables explicativas con su mediana. Esta decisión permite conservar más observaciones, pero también tiene límites. Algunas variables, como el ingreso del hogar o el empleo del padre, tienen menor cobertura que otras, por lo que su importancia debe interpretarse con cuidado.

3 Diseño empírico general

El diseño empírico es predictivo, no causal. Por eso, no interpretamos los resultados como efectos de una variable sobre la violencia, sino como evidencia sobre qué información ayuda más a anticiparla. La parte central del trabajo consiste en comparar tres modelos que predicen el mismo resultado, la agresión física entre los 18 y los 23 años, pero desde muestras distintas.

El primer modelo es el modelo global. Incluye a todas las personas con información suficiente y responde una pregunta general: qué variables predicen mejor la agresión física posterior. El segundo modelo es el modelo de inicio. En este caso dejamos solamente a quienes no habían reportado agresión física entre los 14 y los 17 años. Lo usamos para estudiar qué variables predicen que una persona empiece a reportar agresión después de la adolescencia. El tercer modelo es el modelo de persistencia. Aquí dejamos solamente a quienes sí habían reportado agresión física entre los 14 y los 17 años. Lo usamos para estudiar qué variables predicen que esa conducta continúe entre los 18 y los 23 años. En los modelos de inicio y persistencia quitamos la agresión temprana como predictor, porque esa variable ya se usa para definir a qué grupo pertenece cada persona.

Escogimos esta separación porque creemos que no basta con saber si la agresión pasada predice la agresión futura. También importa saber si las variables que anticipan el primer reporte de agresión son las mismas que anticipan la continuidad de esa conducta. Esta distinción es útil para política pública. Si el inicio se puede anticipar con variables del entorno, entonces tiene sentido pensar en prevención temprana. Si la persistencia no se puede predecir bien, entonces habría que tener cuidado con modelos que pretendan clasificar a jóvenes como casos de alto riesgo.

Estimamos los modelos con *random forest*, un método de aprendizaje de máquina que combina muchos árboles de decisión (Breiman 2001). La predicción final se obtiene promediando las predicciones de todos los árboles. En términos formales, la probabilidad estimada para una persona con características x es $\hat{p}(x) = \frac{1}{B} \sum_{b=1}^B \hat{p}_b(x)$, donde B es el número de árboles y $\hat{p}_b(x)$ es la proporción de casos violentos en la hoja a la que llega esa persona en el árbol b . Usamos este método porque permite trabajar con muchas variables al mismo tiempo y porque nos da medidas de importancia de variables, que son centrales para responder nuestra pregunta.

Para medir la importancia de cada variable usamos dos criterios. El primero es la reducción de impureza de Gini. En cada árbol, el algoritmo separa los datos buscando grupos más homogéneos, y el índice de Gini se define como $G = 1 - \sum_k p_k^2$, donde p_k representa la proporción de la clase k dentro de un nodo. Una variable es más importante si ayuda más a mejorar esas separaciones. Como esta medida puede favorecer variables con muchos valores posibles (Strobl et al. 2007), también usamos importancia por permutación. La idea es que, si una variable importa, mezclar sus valores al azar debería empeorar la predicción. La expresamos como $PI_j = A - \frac{1}{R} \sum_{r=1}^R A_{\pi_j^{(r)}}$, donde A es el área bajo la curva ROC original y $A_{\pi_j^{(r)}}$ es el área obtenida después de permutar la variable j en la repetición r .

Para evaluar el desempeño, separamos 20 por ciento de los datos como muestra de prueba y entrenamos el modelo con el 80 por ciento restante. Además, usamos validación cruzada de cinco pliegues. En ambos casos reportamos el área bajo la curva ROC, que puede interpretarse como la probabilidad de que el modelo asigne un riesgo mayor a una persona que sí reportó agresión que a una persona que no la reportó. Como la agresión física entre los 18 y los 23 años es un evento minoritario, usamos pesos inversos a la frecuencia de cada clase para que el modelo no aprenda a favorecer sistemáticamente la categoría más común. Por último, usamos análisis de componentes principales como ejercicio descriptivo para ver si las conductas de riesgo se mueven juntas. No usamos este ejercicio para hacer predicción individual, sino para interpretar si existe una dimensión común detrás de las conductas adolescentes.

4 Resultados

El primer modelo que planteamos fue el modelo global. Este modelo usa a toda la muestra disponible y busca predecir si una persona reportó agresión física entre los 18 y los 23 años. Su desempeño fue el más alto de los tres modelos: obtuvo un área bajo la curva de 0.80 en la muestra de prueba y de 0.76 en validación cruzada, como se muestra en la Tabla 1. El resultado principal de este modelo es que la agresión temprana concentra la mayor parte de la información predictiva. En la Tabla 2 y en la Figura 2 del anexo se observa que esta variable es la más importante tanto por reducción de impureza como por permutación. La diferencia descriptiva también es clara: entre quienes reportaron agresión entre los 14 y los 17 años, 37.4 por ciento volvió a reportarla entre los 18 y los 23 años. Entre quienes no habían reportado agresión temprana, la proporción fue de 10.6 por ciento. Después de la agresión temprana aparecen, con menor peso, habilidad cognitiva, ingreso del hogar, venta temprana de drogas, sexo y pertenencia a pandillas.

El segundo modelo fue el modelo de inicio. Este modelo solo incluye a las 6,568 personas que no habían reportado agresión física entre los 14 y los 17 años. La pregunta aquí es distinta: no queremos saber quién repite una conducta, sino quién empieza a reportarla en la adultez joven. El modelo obtuvo un área bajo la curva de 0.71 en la muestra de prueba y de 0.70 en validación cruzada. Esto indica que sí hay información útil para anticipar el inicio de la agresión, aunque la predicción no es perfecta. Las variables con mayor importancia fueron habilidad cognitiva, edad de la madre al nacimiento, pertenencia a pandillas, ingreso del hogar, consumo de alcohol, sexo y razón de pobreza, como se muestra en la Tabla 3 y en la Figura 4 del anexo. En conjunto, estos resultados sugieren que el inicio de la agresión no se relaciona con una sola variable, sino con una combinación de características individuales, entorno familiar y conductas de riesgo.

El tercer modelo fue el modelo de persistencia. Este modelo solo incluye a las 2,029 personas que sí habían reportado agresión física entre los 14 y los 17 años. Su objetivo es predecir quién continúa reportando agresión entre los 18 y los 23 años. Aquí el desempeño baja de forma importante: el área bajo la curva fue de 0.58 en la muestra de prueba y de 0.62 en validación cruzada. En términos prácticos, esto significa que el modelo apenas mejora una clasificación hecha casi al azar. Las variables con mayor importancia de Gini fueron razón de pobreza, habilidad cognitiva, ingreso del

hogar, edad de la madre, venta temprana de drogas, portación de arma y arresto antes de los 17 años. Sin embargo, como el desempeño general es bajo, estos resultados deben interpretarse con cuidado. Las variables disponibles no permiten distinguir con mucha precisión quién seguirá agrediendo una vez que ya hubo agresión temprana.

La comparación entre los tres modelos es el resultado más importante del trabajo. El modelo global funciona bien porque aprovecha una señal muy fuerte: la agresión temprana. Cuando separamos a la muestra, vemos que el inicio se puede predecir de manera razonable, pero la persistencia es mucho más difícil de anticipar. Esto responde directamente a la pregunta del diseño empírico: los factores que ayudan a identificar a quienes podrían empezar a reportar agresión no producen una predicción igual de clara entre quienes ya habían reportado agresión en la adolescencia.

El análisis de componentes principales aporta una lectura complementaria a los modelos. La Figura 3 muestra que el primer componente explica cerca de 20 por ciento de la varianza y carga positivamente sobre distintas conductas antisociales y de riesgo, como vender drogas, consumir marihuana, destruir propiedad, robar, agredir o portar un arma. Ese componente se correlaciona en 0.30 con la agresión adulta. Para nosotros, esto sugiere que las conductas adolescentes no deben leerse como hechos completamente aislados. Más bien, parecen formar un patrón común, consistente con la idea de conducta problema de Jessor y Jessor (1977) y con la teoría general del crimen de Gottfredson y Hirschi (1990).

Los contrastes bivariados de la Tabla 4 son consistentes con la literatura. La tasa de agresión adulta fue mayor entre hombres que entre mujeres, 21.7 frente a 11.9 por ciento. También fue mayor en personas que crecieron en estructuras familiares distintas a dos padres biológicos, lo que coincide con la evidencia revisada por Loeber y Stouthamer-Loeber (1986) sobre factores familiares. Aun así, en los modelos predictivos algunas de estas variables quedan por debajo de conductas tempranas más directas. Nuestra interpretación es que parte de la relación entre contexto familiar y violencia posterior puede pasar por lo que la persona vive y hace durante la adolescencia (Sampson y Laub 1993).

5 Conclusión

Nuestro principal hallazgo es que la agresión temprana es el predictor más fuerte de la agresión física en la adultez joven. Dicho de forma simple, quienes reportaron haber agredido a alguien entre los 14 y los 17 años tuvieron una probabilidad mucho más alta de reportarlo otra vez entre los 18 y los 23. Este resultado coincide con estudios previos sobre la continuidad de conductas antisociales (Farrington 2003; Moffitt 1993). Sin embargo, lo más importante del trabajo está en separar el inicio de la persistencia. El inicio de la agresión se puede anticipar con un desempeño razonable a partir de variables observadas en la adolescencia, mientras que la persistencia es mucho más difícil de predecir con la información disponible.

La implicación de política pública es directa. Parece más útil invertir en prevención temprana que intentar señalar con mucha precisión qué jóvenes seguirán siendo violentos. Si variables como consumo temprano de alcohol, pertenencia a pandillas, habilidad cognitiva, ingreso del hogar y pobreza ayudan a anticipar el inicio, entonces tiene sentido fortalecer intervenciones en edades tempranas y en contextos vulnerables. Esta lectura es consistente con la evidencia de Heckman (2006) sobre la importancia de invertir temprano en poblaciones desfavorecidas. Al mismo tiempo, el bajo desempeño del modelo de persistencia nos hace pensar que las herramientas de predicción individual deben usarse con cuidado, porque una predicción débil puede producir errores con consecuencias serias.

El trabajo también tiene límites. La agresión está medida por autorreporte y no distingue entre distintos niveles de gravedad. Además, algunas variables tienen cobertura parcial y fueron imputadas con la mediana, lo cual puede reducir o distorsionar su importancia. Por último, la cohorte corresponde a jóvenes nacidos en Estados Unidos entre 1980 y 1984, por lo que cualquier lectura para México debe hacerse con cuidado. Aun con estas limitaciones, el resultado central es claro: prevenir el inicio de la violencia parece una meta más alcanzable que predecir quién continuará agrediendo después.

6 Anexo: tablas y figuras

Tabla 1: Desempeño de los tres modelos de *random forest*.

Modelo	Muestra	Prevalencia	AUC prueba	AUC validación cruzada
Global (14-17 a 18-23)	8,609	16.9 %	0.80	0.76 (± 0.03)
Inicio (sin agresión temprana)	6,568	10.6 %	0.71	0.70 (± 0.04)
Persistencia (con agresión temprana)	2,029	37.4 %	0.58	0.62 (± 0.04)

Tabla 2: Importancia de variables en el modelo global.

Variable	Importancia de Gini	Importancia por permutación
Agresión temprana (14-17)	0.228	0.079
Habilidad cognitiva (ASVAB)	0.080	0.007
Ingreso del hogar (14-17)	0.064	bajo
Venta de drogas temprana	0.059	0.003
Razón de pobreza (1997)	0.055	bajo
Edad de la madre al nacer	0.055	0.005
Destrucción de propiedad temprana	0.053	0.003
Sexo (hombre)	0.049	0.014
Pandilla temprana	0.044	0.010
Alcohol temprano	0.041	0.014

Tabla 3: Importancia de Gini en los modelos de inicio y persistencia.

Modelo de inicio	Importancia	Modelo de persistencia	Importancia
Habilidad cognitiva	0.142	Razón de pobreza	0.116
Edad de la madre	0.091	Habilidad cognitiva	0.098
Pandilla temprana	0.087	Ingreso del hogar	0.098
Ingreso del hogar	0.084	Edad de la madre	0.091
Alcohol temprano	0.081	Venta de drogas temprana	0.084
Sexo (hombre)	0.079	Portación de arma temprana	0.055
Razón de pobreza	0.075	Arresto antes de los 17	0.046

Tabla 4: Tasas de agresión adulta por subgrupo.

Grupo	Categoría	Tasa de agresión 18-23
Sexo	Hombre	21.7 %
Sexo	Mujer	11.9 %
Raza o etnicidad	Afroamericano	21.5 %
Raza o etnicidad	Hispano	16.8 %
Raza o etnicidad	Blanco u otro	14.5 %
Estructura familiar	Dos padres biológicos	13.5 %
Estructura familiar	Un solo padre	18.4 %
Estructura familiar	Otra estructura	22.9 %




Figura 1: Curva edad-agresión en la NLSY97. La prevalencia del autorreporte de agresión asciende en la adolescencia media y desciende en la adultez joven, replicando el patrón clásico edad-crimen.




Figura 2: Importancia de variables en el modelo global de *random forest*. La agresión temprana domina sobre todas las demás variables.




Figura 3: Análisis de componentes principales de los factores de riesgo medidos entre los 14 y 17 años. El primer componente carga sobre todas las conductas antisociales a la vez, lo que evidencia un factor general de delincuencia.




Figura 4: Importancia de variables en el modelo de inicio. Los predictores son marcadores del contexto social, no señales criminales.




Figura 5: Importancia de variables en el modelo de persistencia. La capacidad predictiva es baja y solo asoman, de forma débil, la desventaja socioeconómica y el arraigo delictivo.

Referencias

- Breiman, Leo. 2001. «Random Forests». *Machine Learning* 45(1): 5-32.
- Farrington, David P. 2003. «Developmental and Life-Course Criminology: Key Theoretical and Empirical Issues». *Criminology* 41(2): 221-55.
- Gottfredson, Michael R., y Travis Hirschi. 1990. *A General Theory of Crime*. Stanford, CA: Stanford University Press.
- Heckman, James J. 2006. «Skill Formation and the Economics of Investing in Disadvantaged Children». *Science* 312(5782): 1900-1902.
- Hirschi, Travis. 1969. *Causes of Delinquency*. Berkeley: University of California Press.
- Hirschi, Travis, y Michael Gottfredson. 1983. «Age and the Explanation of Crime». *American Journal of Sociology* 89(3): 552-84.
- Jessor, Richard, y Shirley L. Jessor. 1977. *Problem Behavior and Psychosocial Development: A Longitudinal Study of Youth*. New York: Academic Press.
- Lipsey, Mark W., y James H. Derzon. 1998. «Predictors of Violent or Serious Delinquency in Adolescence and Early Adulthood: A Synthesis of Longitudinal Research». En *Serious and Violent Juvenile Offenders: Risk Factors and Successful Interventions*, eds. Rolf Loeber y David P. Farrington. Thousand Oaks, CA: Sage, 86-105.
- Loeber, Rolf, y Magda Stouthamer-Loeber. 1986. «Family Factors as Correlates and Predictors of Juvenile Conduct Problems and Delinquency». *Crime and Justice* 7: 29-149.

- Moffitt, Terrie E. 1993. «Adolescence-Limited and Life-Course-Persistent Antisocial Behavior: A Developmental Taxonomy». *Psychological Review* 100(4): 674-701.
- Nagin, Daniel S., y Raymond Paternoster. 1991. «On the Relationship of Past to Future Participation in Delinquency». *Criminology* 29(2): 163-89.
- Sampson, Robert J., y John H. Laub. 1993. *Crime in the Making: Pathways and Turning Points Through Life*. Cambridge, MA: Harvard University Press.
- Strobl, Carolin, Anne-Laure Boulesteix, Achim Zeileis, y Torsten Hothorn. 2007. «Bias in Random Forest Variable Importance Measures: Illustrations, Sources and a Solution». *BMC Bioinformatics* 8: 25.
- United States Department of Justice, Office of Justice Programs, Bureau of Justice Statistics. 2014. «Recidivism in the National Longitudinal Survey of Youth 1997 - Standalone Data (Rounds 1 to 13)». doi:[10.3886/ICPSR34562.v1](https://doi.org/10.3886/ICPSR34562.v1).