

Inicio y persistencia de la violencia juvenil: un análisis de importancia de variables sobre la Encuesta Nacional Longitudinal de la Juventud de 1997

[Nombres del equipo]

2026-05-25

Abstract

¿Podemos saber, mirando la adolescencia de una persona, si será violenta de adulta? Lo investigamos con la Encuesta Nacional Longitudinal de la Juventud de 1997 (estudio ICPSR 34562), que siguió a casi nueve mil jóvenes estadounidenses durante más de una década. Construimos un indicador de agresión física entre los 18 y 23 años y lo predecimos con información medida entre los 14 y 17, usando bosques aleatorios e importancia de variables, junto con un análisis de componentes principales. Encontramos que la mejor pista sobre la violencia futura es la violencia pasada y que las conductas de riesgo forman un solo patrón. Al separar la muestra surge lo más revelador: el inicio de la violencia se puede anticipar desde el entorno social, pero su persistencia resulta casi imposible de predecir. Esto respalda la prevención temprana y advierte contra la predicción actuarial del riesgo.

1 Mérito intelectual del proyecto

Pocos problemas de política pública dejan una huella tan larga como la violencia juvenil, porque daña a las víctimas y tuerce el rumbo de quien la ejerce. Desde hace décadas, la criminología que estudia el curso de la vida ha llegado a una conclusión que sorprende por su solidez: la conducta antisocial es muy estable en el tiempo. Dicho de otro modo, el niño que se mete en problemas tiende a convertirse en el adulto que delinque (Moffitt 1993; Sampson y Laub 1993). La pregunta natural es por qué ocurre esto. Gottfredson y Hirschi (1990) responden que existe un rasgo duradero, el bajo autocontrol, que empuja a la persona hacia toda clase de conductas problemáticas. Hirschi (1969), en cambio, pone el acento en los lazos que nos atan a la sociedad: cuando los vínculos con la familia, la escuela o el trabajo se debilitan, el freno que contiene la conducta se afloja.

Ambas explicaciones han marcado el campo, pero esconden una tensión crucial para quien diseña una intervención: una cosa es entender quién empieza a ser violento y otra muy distinta es entender quién sigue siéndolo. De ahí nacen las dos preguntas que guían este trabajo. La primera es directa: ¿qué rasgos de la adolescencia anticipan mejor la agresión en la adultez joven? La segunda es más fina y, en nuestra opinión, más interesante: ¿los factores que predicen que alguien comience a ser violento son los mismos que predicen que continúe siéndolo?

La diferencia no es un capricho académico, pues el presupuesto que un gobierno dedica a la prevención es limitado y conviene saber si vale más vigilar señales sociales tempranas o dar seguimiento a quienes ya delinquieron.

Nuestra contribución es a la vez metodológica y sustantiva. Por el lado del método, llevamos la importancia de variables de los bosques aleatorios y el análisis de componentes principales a una cohorte nacional representativa de Estados Unidos, y no a las muestras clínicas o locales sobre las que se apoya buena parte de la literatura clásica (Lipsey y Derzon 1998). Por el lado del contenido, al separar con datos el inicio de la persistencia le ponemos número a una asimetría que las teorías insinúan pero casi nunca miden. Con ello dialogamos con la síntesis de predictores de Lipsey y Derzon (1998) y con la vieja discusión entre heterogeneidad poblacional y dependencia de estado que planteó Nagin y Paternoster (1991).

2 Variables y datos

Los datos vienen del estudio ICPSR 34562, una versión preparada por el Bureau of Justice Statistics a partir de la Encuesta Nacional Longitudinal de la Juventud de 1997, conocida como NLSY97 (United States Department of Justice, Office of Justice Programs, Bureau of Justice Statistics 2014). La encuesta tomó a una muestra representativa de 8,984 personas nacidas en Estados Unidos entre 1980 y 1984 y las entrevistó año con año desde 1997, de manera que podemos seguir a cada quien a lo largo de su adolescencia y su entrada a la adultez. Hay un detalle del archivo que conviene tener presente desde el inicio, y es que las variables no están organizadas por año de calendario sino por la edad que tenía la persona, así que cada columna describe su situación al cumplir cierta edad. Esto trae una consecuencia práctica: las edades más tempranas solo se observan bien en los más jóvenes de la muestra, porque quienes nacieron en 1980 ya habían pasado los catorce años cuando arrancó la encuesta.

Nuestra variable principal es sencilla de enunciar. Vale uno si la persona dijo haber agredido físicamente a alguien con intención de hacerle daño en al menos uno de los años entre los 18 y los 23, y vale cero si no lo hizo. Elegimos esa ventana adulta por dos razones. La primera es que el autorreporte de agresión se recoge con buena cobertura entre los 18 y los 20 años. La segunda es que los datos de los 24 y 25 años provienen de una submuestra de personas en prisión, de modo que incluirlos inflaría de forma artificial la violencia. De las 8,984 personas originales, 8,609 tienen al menos una respuesta válida sobre agresión en esa ventana, y entre ellas el 16.9 por ciento reportó haber agredido a alguien.

Todas las variables explicativas se midieron antes de esa ventana, ya sea en el retrato de origen levantado en 1997 o en las conductas observadas entre los 14 y los 17 años. Respetar ese orden en el tiempo es lo que evita una trampa común, la de predecir la violencia con información recogida al mismo tiempo que ella, lo que volvería el ejercicio circular y vacío. El retrato de origen reúne el sexo, la raza o etnicidad que la persona declara, la estructura de su familia, la escolaridad y el empleo de sus padres, cuántos hermanos tiene, la relación entre el ingreso del hogar y la línea de pobreza, la edad de la madre cuando nació y su percentil en la batería de aptitudes ASVAB, que usamos como una aproximación a la habilidad cognitiva. Las conductas adolescentes incluyen si

agredió, destruyó propiedad, robó, vendió drogas, portó un arma o anduvo en pandillas, junto con su consumo de alcohol, tabaco, marihuana y drogas duras, y su primer contacto con la justicia, medido como haber sido arrestado o encarcelado antes de los 17. La Figura 1 del anexo dibuja en estos datos la conocida curva que relaciona la edad con el delito, con un repunte de la agresión en plena adolescencia y una caída posterior, tal como describieron Hirschi y Gottfredson (1983).

Como en toda encuesta que sigue a las personas durante años, no faltan los huecos, en parte por la estructura de edades que ya explicamos y en parte porque algunos participantes se pierden por el camino. Tratamos como dato faltante todos los códigos especiales del NLSY97 y rellenamos las variables explicativas con su mediana. Vale la pena ser honestos en un punto: variables como el empleo del padre o el ingreso del hogar solo se observan en cerca de dos tercios de la muestra, así que su importancia conviene leerla con cierta reserva.

3 Diseño empírico general

Nuestro objetivo es predictivo y no causal, lo que cambia la pregunta que le hacemos a cada variable. No nos interesa tanto qué efecto produce, sino qué tan útil resulta para anticipar la conducta violenta. La herramienta principal es el bosque aleatorio, un método que se entiende mejor con una imagen. Pensemos en un comité de árboles de decisión, donde cada árbol aprende de una muestra distinta de los datos y, en cada bifurcación, solo puede mirar un subconjunto al azar de las variables (Breiman 2001). Ningún árbol por separado es muy confiable, pero el promedio del comité sí lo es. La probabilidad que el bosque le asigna a una persona es justamente ese promedio, $\hat{p}(x) = \frac{1}{B} \sum_{b=1}^B \hat{p}_b(x)$, donde B es el número de árboles y $\hat{p}_b(x)$ es la proporción de casos violentos en la hoja del árbol b a la que llega la persona descrita por el vector de características x .

Cada árbol decide dónde partir los datos buscando hojas lo más puras posible, y para medir esa pureza usa el índice de Gini, $G = 1 - \sum_k p_k^2$, donde p_k es la proporción de la clase k dentro del nodo. Un nodo es puro cuando casi todos sus casos pertenecen a la misma clase, y entonces G se acerca a cero. De ahí surge la primera medida de importancia que usamos: para cada variable sumamos cuánta impureza ayuda a eliminar en todas las particiones donde aparece, ponderando por cuántos casos pasan por cada nodo, y luego promediamos entre los árboles. Esta medida es muy informativa, pero tiene un sesgo conocido, pues tiende a premiar a las variables que toman muchos valores distintos (Strobl et al. 2007). Para no fiarnos de una sola vara, la acompañamos con la importancia por permutación, que sigue una idea muy intuitiva: si una variable de verdad importa, barajar sus valores al azar debería empeorar las predicciones. Formalmente, $PI_j = A - \frac{1}{R} \sum_{r=1}^R A_{\pi_j^{(r)}}$, donde A es el área bajo la curva ROC del modelo y $A_{\pi_j^{(r)}}$ es esa misma área cuando la variable j se ha barajado en la repetición r . Confiamos en una variable cuando se mantiene alta en ambas medidas a la vez.

Para saber si el modelo predice bien y no solo memoriza, apartamos un 20 por ciento de los datos como prueba y entrenamos con el 80 por ciento restante, y repetimos el ejercicio con validación cruzada de cinco pliegues. En ambos casos reportamos el área bajo la curva ROC, que se interpreta como la probabilidad de que el modelo le asigne un riesgo mayor a una persona violenta que

a una que no lo es. Como la conducta violenta es minoritaria, le damos a cada clase un peso inverso a su frecuencia para que el modelo no caiga en la tentación de ignorar a la minoría. Por último, y solo como herramienta descriptiva, aplicamos un análisis de componentes principales sobre las conductas y las variables socioeconómicas, todas estandarizadas. El primer componente es la dirección que más varianza captura, $w_1 = \arg \max_{\|w\|=1} \text{Var}(Xw)$, y los siguientes son los vectores propios que le siguen en la matriz de covarianzas. Lo que buscamos con esto es ver si las distintas conductas de riesgo se agrupan en una sola dimensión de fondo.

Con estas piezas armamos tres modelos que, juntos, cuentan la historia completa. El primero usa a toda la muestra y todas las variables. Los otros dos parten a la gente según haya agredido o no entre los 14 y 17 años, y dejan fuera ese indicador como predictor para no hacer trampa. El modelo de inicio se queda con quienes no habían agredido temprano y pregunta qué anticipa que empiecen; el modelo de persistencia se queda con quienes sí lo habían hecho y pregunta qué anticipa que continúen. Tenemos dos expectativas claras. Si la conducta antisocial nace de un rasgo estable, como sostienen Gottfredson y Hirschi (1990), la agresión temprana debería dominar el modelo global. Y si el inicio y la persistencia son procesos distintos, los predictores de uno y otro modelo deberían separarse de forma notoria.

4 Resultados

El modelo global no deja lugar a dudas sobre la continuidad de la conducta. Como muestran la Tabla 2 y la Figura 2 del anexo, la agresión temprana es, por mucho, el predictor más importante, y lo es tanto por reducción de impureza como por permutación, muy por encima de cualquier variable económica o demográfica. El contraste en crudo es elocuente: de quienes reportaron agresión en la adolescencia, el 37.4 por ciento volvió a reportarla en la adultez joven, frente a apenas el 10.6 por ciento de quienes no la habían reportado. El bosque alcanza un área bajo la curva de 0.80 en la muestra de prueba y de 0.76 en validación cruzada, un desempeño respetable cuando lo que se intenta predecir es algo tan resbaladizo como la conducta humana. Detrás de la agresión temprana, ya con mucho menos peso, aparecen la habilidad cognitiva, el ingreso del hogar, la venta temprana de drogas, el sexo y el paso por pandillas.

El análisis de componentes principales, en la Figura 3 del anexo, apunta en la misma dirección y agrega un matiz revelador. El primer componente explica cerca del 20 por ciento de la varianza y carga de forma positiva sobre todas las conductas antisociales tempranas al mismo tiempo, desde vender drogas o fumar marihuana hasta destruir propiedad, robar, agredir o portar un arma. Ese mismo componente se correlaciona en 0.30 con la violencia adulta. En otras palabras, las conductas de riesgo no van cada una por su lado, sino que parecen brotar de una misma raíz, justo lo que anticipan la idea del síndrome de conducta problema de Jessor y Jessor (1977) y la noción de un factor general detrás del crimen en Gottfredson y Hirschi (1990).

Pero el hallazgo que le da sentido a todo el trabajo aparece cuando separamos el inicio de la persistencia, y se resume en la Tabla 3 y la Figura 4 del anexo. Entre las 6,568 personas que no habían agredido temprano, el modelo de inicio adivina bastante bien quién empezará a ser violento, con un área bajo la curva de 0.71. Lo interesante es de dónde sale esa capacidad, porque no son señales criminales sino marcadores del entorno: el sexo, el consumo temprano de alcohol y tabaco, el paso por pandillas, una habilidad cognitiva baja, la edad de la madre al nacer y el ingreso del hogar. La imagen cambia por completo del otro lado. Entre las 2,029 personas que ya habían agredido, el modelo de persistencia apenas le gana al azar, con un área bajo la curva de 0.58. Las variables que tenemos no alcanzan a distinguir quién seguirá siendo violento, y las pocas señales

que asoman, todas débiles, apuntan a la desventaja económica, medida por la razón de pobreza y el ingreso del hogar, y al arraigo en la actividad delictiva, como vender drogas, portar armas o haber sido arrestado.

Los contrastes simples de la Tabla 4 del anexo encajan con esta historia y con lo que dice la literatura. La tasa de agresión adulta es casi del doble entre los hombres que entre las mujeres, 21.7 frente a 11.9 por ciento, y es más alta entre quienes crecieron en hogares distintos al de dos padres biológicos, lo que coincide con lo que Loeber y Stouthamer-Loeber (1986) encontró sobre el peso de los factores familiares. Y sin embargo, esa misma estructura familiar y la escolaridad de los padres, pese a su relación visible con la violencia, quedan en posiciones bajas dentro de los modelos. Esto sugiere que su influencia no es directa, sino que actúa a través de las conductas tempranas, tal como propone la mirada del curso de vida (Sampson y Laub 1993).

5 Conclusión

Lo primero que deja este trabajo es una confirmación. Sobre una cohorte nacional y con aprendizaje automático, encontramos lo que la criminología del desarrollo viene diciendo desde hace años: la conducta agresiva es muy estable y su mejor predictor es la agresión que vino antes (Farrington 2003; Moffitt 1993). Pero la aportación más valiosa no es esa, sino la asimetría que aparece al separar el inicio de la persistencia: el inicio se deja anticipar a partir de señales sociales presentes antes de cualquier acto violento, mientras que la persistencia, una vez instalada la conducta, se vuelve casi imposible de predecir. Esa brecha dialoga con el viejo debate entre heterogeneidad poblacional y dependencia de estado de Nagin y Paternoster (1991).

Las implicaciones de política son claras. Que el inicio se anuncie a través del entorno económico, el consumo de sustancias y la habilidad cognitiva refuerza el argumento a favor de la prevención temprana y de amplio alcance, en sintonía con la evidencia sobre lo rentable que es invertir en la primera infancia de las poblaciones desfavorecidas (Heckman 2006). La otra cara es una advertencia. Si la persistencia apenas se puede predecir, las herramientas actuariales que pretenden etiquetar a jóvenes de alto riesgo descansan sobre arena, porque un modelo que casi no le gana al azar produciría una avalancha de errores con consecuencias serias para personas concretas. Que la desventaja económica gane peso en el grupo que ya delinque sugiere que las condiciones estructurales sostienen las trayectorias delictivas, lo que invita a reducir la pobreza y abrir oportunidades, no solo a vigilar.

Conviene reconocer los límites del trabajo. La agresión que medimos es autorreportada y no separa la simple de la agravada, así que capta algo más ancho que el delito grave. La pérdida de seguimiento y el relleno de variables con cobertura parcial pueden restar importancia a algunos factores, y como los datos son de una cohorte estadounidense de los años ochenta, cualquier traslado a otros contextos, en especial a México, pide prudencia. Hacia adelante valdría la pena repetir el análisis con definiciones más finas de violencia y modelos de grupos latentes. Con todo, la conclusión se sostiene: prevenir el inicio de la violencia es una meta más alcanzable que predecir su persistencia, y la política pública haría bien en repartir sus recursos en consecuencia.

6 Anexo: tablas y figuras

Tabla 1: Desempeño de los tres modelos de bosque aleatorio.

Modelo	Muestra	Prevalencia	AUC prueba	AUC validación cruzada
Global (14-17 a 18-23)	8,609	16.9 %	0.80	0.76 (± 0.03)
Inicio (sin agresión temprana)	6,568	10.6 %	0.71	0.70 (± 0.04)
Persistencia (con agresión temprana)	2,029	37.4 %	0.58	0.62 (± 0.04)

Tabla 2: Importancia de variables en el modelo global.

Variable	Importancia de Gini	Importancia por permutación
Agresión temprana (14-17)	0.228	0.079
Habilidad cognitiva (ASVAB)	0.080	0.007
Ingreso del hogar (14-17)	0.064	bajo
Venta de drogas temprana	0.059	0.003
Razón de pobreza (1997)	0.055	bajo
Edad de la madre al nacer	0.055	0.005
Destrucción de propiedad temprana	0.053	0.003
Sexo (hombre)	0.049	0.014
Pandilla temprana	0.044	0.010
Alcohol temprano	0.041	0.014

Tabla 3: Importancia de Gini en los modelos de inicio y persistencia.

Modelo de inicio	Importancia	Modelo de persistencia	Importancia
Habilidad cognitiva	0.142	Razón de pobreza	0.116
Edad de la madre	0.091	Habilidad cognitiva	0.098
Pandilla temprana	0.087	Ingreso del hogar	0.098
Ingreso del hogar	0.084	Edad de la madre	0.091
Alcohol temprano	0.081	Venta de drogas temprana	0.084
Sexo (hombre)	0.079	Portación de arma temprana	0.055
Razón de pobreza	0.075	Arresto antes de los 17	0.046

Tabla 4: Tasas de agresión adulta por subgrupo.

Grupo	Categoría	Tasa de agresión 18-23
Sexo	Hombre	21.7 %
Sexo	Mujer	11.9 %
Raza o etnicidad	Afroamericano	21.5 %
Raza o etnicidad	Hispano	16.8 %
Raza o etnicidad	Blanco u otro	14.5 %
Estructura familiar	Dos padres biológicos	13.5 %
Estructura familiar	Un solo padre	18.4 %
Estructura familiar	Otra estructura	22.9 %




Figura 1: Curva edad-agresión en la NLSY97. La prevalencia del autorreporte de agresión asciende en la adolescencia media y desciende en la adultez joven, replicando el patrón clásico edad-crimen.




Figura 2: Importancia de variables en el modelo global de bosque aleatorio. La agresión temprana domina sobre todas las demás variables.




Figura 3: Análisis de componentes principales de los factores de riesgo medidos entre los 14 y 17 años. El primer componente carga sobre todas las conductas antisociales a la vez, lo que evidencia un factor general de delincuencia.




Figura 4: Importancia de variables en el modelo de inicio. Los predictores son marcadores del contexto social, no señales criminales.




Figura 5: Importancia de variables en el modelo de persistencia. La capacidad predictiva es baja y solo asoman, de forma débil, la desventaja socioeconómica y el arraigo delictivo.

Referencias

- Breiman, Leo. 2001. «Random Forests». *Machine Learning* 45(1): 5-32.
- Farrington, David P. 2003. «Developmental and Life-Course Criminology: Key Theoretical and Empirical Issues». *Criminology* 41(2): 221-55.
- Gottfredson, Michael R., y Travis Hirschi. 1990. *A General Theory of Crime*. Stanford, CA: Stanford University Press.
- Heckman, James J. 2006. «Skill Formation and the Economics of Investing in Disadvantaged Children». *Science* 312(5782): 1900-1902.
- Hirschi, Travis. 1969. *Causes of Delinquency*. Berkeley: University of California Press.
- Hirschi, Travis, y Michael Gottfredson. 1983. «Age and the Explanation of Crime». *American Journal of Sociology* 89(3): 552-84.
- Jessor, Richard, y Shirley L. Jessor. 1977. *Problem Behavior and Psychosocial Development: A Longitudinal Study of Youth*. New York: Academic Press.
- Lipsey, Mark W., y James H. Derzon. 1998. «Predictors of Violent or Serious Delinquency in Adolescence and Early Adulthood: A Synthesis of Longitudinal Research». En *Serious and Violent Juvenile Offenders: Risk Factors and Successful Interventions*, eds. Rolf Loeber y David P. Farrington. Thousand Oaks, CA: Sage, 86-105.
- Loeber, Rolf, y Magda Stouthamer-Loeber. 1986. «Family Factors as Correlates and Predictors of Juvenile Conduct Problems and Delinquency». *Crime and Justice* 7: 29-149.

- Moffitt, Terrie E. 1993. «Adolescence-Limited and Life-Course-Persistent Antisocial Behavior: A Developmental Taxonomy». *Psychological Review* 100(4): 674-701.
- Nagin, Daniel S., y Raymond Paternoster. 1991. «On the Relationship of Past to Future Participation in Delinquency». *Criminology* 29(2): 163-89.
- Sampson, Robert J., y John H. Laub. 1993. *Crime in the Making: Pathways and Turning Points Through Life*. Cambridge, MA: Harvard University Press.
- Strobl, Carolin, Anne-Laure Boulesteix, Achim Zeileis, y Torsten Hothorn. 2007. «Bias in Random Forest Variable Importance Measures: Illustrations, Sources and a Solution». *BMC Bioinformatics* 8: 25.
- United States Department of Justice, Office of Justice Programs, Bureau of Justice Statistics. 2014. «Recidivism in the National Longitudinal Survey of Youth 1997 - Standalone Data (Rounds 1 to 13)». doi:[10.3886/ICPSR34562.v1](https://doi.org/10.3886/ICPSR34562.v1).