

Predictores adolescentes de agresión en la adultez joven

Jerónimo Deli Larios y Juan Pablo Cordero Mayorga

2026-05-26

Abstract

Este trabajo estudia qué información observada antes de la adultez predice mejor el autorreporte de agresión física entre los 18 y los 23 años. Usamos el archivo ICPSR 34562, derivado de la NLSY97, y construimos una muestra analítica de 3,737 personas con 26 predictores completos. El diseño es predictivo y asociativo. Primero estimamos modelos de probabilidad lineal jerárquicos con errores robustos, organizados en bloques demográficos, familiares, cognitivos, conductuales, de sustancias y de justicia. Después entrenamos un random forest sobre los mismos predictores y medimos la importancia por permutación de bloques. En ambos enfoques, el bloque de conducta pasada es el que concentra más señal predictiva; después aparecen demografía y justicia/sustancias. La implicación principal es preventiva: las conductas observables en adolescencia son los marcadores más útiles para orientar seguimiento temprano.

1 Mérito intelectual del proyecto

La pregunta central de este trabajo es qué variables medidas antes de la adultez ayudan a anticipar si una persona reportará una agresión física entre los 18 y los 23 años. El objetivo no es estimar un efecto causal de una conducta específica, sino ordenar la información disponible por su capacidad para predecir una trayectoria posterior. La pregunta tiene relevancia de política pública porque la prevención de violencia necesita decidir cuándo y con qué información identificar riesgos. Si la información demográfica o familiar fuera suficiente, bastaría con diagnósticos tempranos y relativamente estables. Si, en cambio, la mayor señal aparece en conductas observables durante la adolescencia, los años inmediatamente anteriores a la adultez tendrían más valor para identificar casos con riesgo alto.

El trabajo usa únicamente el archivo ICPSR 34562, derivado del National Longitudinal Survey of Youth 1997 (United States Department of Justice, Office of Justice Programs, Bureau of Justice Statistics 2014). La base contiene variables organizadas por edad. Esta estructura permite separar temporalmente los predictores y el resultado: las conductas variables en el tiempo se restringen a los 14 a 17 años, mientras que la variable dependiente se define con información de los 18 a los 23 años. Esa separación es el elemento más importante del diseño, porque evita que el modelo use como predictor información contemporánea o posterior al resultado.

La contribución empírica del análisis es comparar dos lecturas de la misma pregunta. La primera es un modelo de probabilidad lineal jerárquico, que permite interpretar coeficientes como cambios en probabilidad y evaluar cuánto aumenta la varianza explicada cuando se agrega cada bloque de variables. La segunda es un random forest, usado como herramienta predictiva no lineal (Breiman 2001). Para que el random forest sea interpretable, el análisis calcula importancia por permutación de bloques, siguiendo la lógica documentada en el propio script de análisis: si romper la información conjunta de un bloque deteriora el AUC, ese bloque contiene señal predictiva relevante (Molnar 2022; Strobl et al. 2008). La comparación es útil porque ambos modelos usan la misma muestra analítica y los mismos bloques.

2 Variables y datos

La base de origen de este proyecto es la National Longitudinal Survey of Youth 1997, conocida como NLSY97. Esta encuesta siguió a una cohorte de 8,984 jóvenes residentes en Estados Unidos nacidos entre 1980 y 1984. La primera ronda se levantó en 1997 y, para el archivo que usamos, la información disponible llega hasta la ronda 13, correspondiente a entrevistas anuales de 1997 a 2009. En esas entrevistas se registraron características familiares, educación, habilidades, consumo de sustancias, contacto con el sistema de justicia y conductas autorreportadas.

Para nuestra pregunta, la utilidad de la NLSY97 está en que varias conductas aparecen medidas por edad. Nuestro interés es saber qué señales disponibles antes de los 18 años ayudan a anticipar agresión física entre los 18 y los 23 años. Como la cohorte nació entre 1980 y 1984, el archivo permite reconstruir una ventana adolescente y una ventana de adultez joven dentro de la misma población. Así podemos construir predictores de los 14 a los 17 años y una variable dependiente posterior sin mezclar los dos periodos. Esta separación es central porque reduce el riesgo de data leakage, es decir, que el modelo use información que en la práctica todavía no estaría disponible al momento de hacer una predicción preventiva.

El archivo específico que usamos es el estudio ICPSR 34562, derivado de la NLSY97 (United States Department of Justice, Office of Justice Programs, Bureau of Justice Statistics 2014). ICPSR funciona como repositorio y distribuidor de datos para investigación social, y en este caso nos permite trabajar con un archivo ya preparado en formato Stata: DS0001/34562-0001-Data.dta. Usamos este archivo porque contiene las variables necesarias para conectar conductas adolescentes con agresión posterior y porque mantiene la organización por edad que necesita nuestro diseño. A partir de ese archivo construimos un conjunto de datos analítico propio. Primero conservamos a las personas con al menos una observación válida de agresión entre los 18 y los 23 años. Después aplicamos eliminación por lista sobre la variable dependiente y los 26 predictores usados en los modelos. La muestra final tiene 3,737 personas.

La variable dependiente principal es ASSAULT_ADULT. Toma el valor de uno si la persona reportó haber cometido una agresión en al menos un año de edad entre los 18 y los 23 años, y cero si tiene información válida en esa ventana y no reportó agresión. Esta definición evita usar EVER_ASSAULT como resultado, porque esa alternativa combinaría edades adolescentes y adultas. Usarla mezclaría la misma ventana temporal que alimenta los predictores y produciría filtración temporal de información.

Los predictores se organizan en cinco bloques. El bloque demográfico incluye sexo, raza o etnicidad, edad de la madre biológica al nacimiento y número de hermanos. El bloque familiar y socioeconómico incluye estructura familiar en 1997, educación parental y razón ingreso-pobreza en 1997. El bloque cognitivo usa ASVAB_SCORE. El bloque de conducta pasada resume, entre los 14 y los 17 años, destrucción de propiedad, robo menor a 50 dólares, robo mayor a 50 dólares, otros delitos contra propiedad, presencia o contacto con pandillas, portación de arma y huida del hogar. El bloque de justicia y sustancias incluye consumo de tabaco, alcohol, marihuana, drogas duras y arresto antes de cumplir 18 años. Para la pregunta del proyecto, los bloques conductuales y de justicia/sustancias son los predictores primarios, porque contienen acciones observables antes del resultado adulto; los bloques demográfico, familiar y cognitivo funcionan como información contextual y de control predictivo.

Para convertir la información original en variables numéricas, las respuestas binarias tipo Yes/No se recodifican como uno y cero. Los códigos negativos y respuestas no válidas se tratan como faltantes. Las variables categóricas nominales, como raza o etnicidad, estructura familiar y educación parental, se convierten en indicadores binarios con una categoría de referencia omitida. Las conductas medidas por edad se resumen como conteos de años válidos entre cero y cuatro; el arresto antes de los 18 años se define como indicador binario. Esta construcción mantiene la información predictiva previa a la adultez sin incorporar datos contemporáneos o posteriores al resultado. El matiz importante es que la restricción de 14 a 17 años aplica a conductas, sustancias y arresto, mientras que demografía, familia, nivel socioeconómico y ASVAB se usan como características basales o tempranas disponibles antes de la ventana adulta.

3 Diseño empírico general

El primer componente del análisis es un modelo de probabilidad lineal, o LPM por sus siglas en inglés. En este modelo, la variable dependiente es binaria: $Y_i = 1$ si la persona reportó agresión física entre los 18 y los 23 años, y $Y_i = 0$ si no la reportó dentro de esa ventana. Estimamos el LPM por mínimos cuadrados ordinarios y usamos errores estándar robustos HC1, porque con una variable dependiente binaria la varianza del error no es constante. La ventaja de este modelo es que sus coeficientes se leen directamente como cambios en probabilidad, medidos en puntos porcentuales. La limitación es que el valor predicho puede quedar por debajo de cero o por encima de uno. Por eso, cuando evaluamos accuracy, usamos un umbral de decisión de 0.5: si la predicción es mayor o igual a 0.5, el modelo clasifica a la persona como caso positivo; si es menor a 0.5, la clasifica como caso negativo. Este umbral funciona como un hiperparámetro de evaluación, no como un coeficiente estimado por el modelo.

Para cada persona i , el modelo general es

$$Y_i = \alpha_m + \sum_{b=1}^m \mathbf{X}'_{ib} \beta_b + \varepsilon_i,$$

donde Y_i es ASSAULT_ADULT, $\mathbf{X}_{ib}$ es el vector de variables del bloque b , β_b es el vector de coeficientes asociado a ese bloque, α_m es la constante del modelo m , y ε_i es el término de error. Todos los modelos se estiman sobre la misma muestra analítica, definida por eliminación por lista en la variable dependiente y en los 26 predictores usados por el modelo completo. Esto permite comparar modelos anidados sin que cambie la composición de la muestra.

Los modelos se incorporan de forma acumulativa:

$$\begin{aligned} M_1 : Y_i &= \alpha_1 + \mathbf{X}'_{i,D} \beta_D + \varepsilon_i, \\ M_2 : Y_i &= \alpha_2 + \mathbf{X}'_{i,D} \beta_D + \mathbf{X}'_{i,F} \beta_F + \varepsilon_i, \\ M_3 : Y_i &= \alpha_3 + \mathbf{X}'_{i,D} \beta_D + \mathbf{X}'_{i,F} \beta_F + \mathbf{X}'_{i,C} \beta_C + \varepsilon_i, \\ M_4 : Y_i &= \alpha_4 + \mathbf{X}'_{i,D} \beta_D + \mathbf{X}'_{i,F} \beta_F + \mathbf{X}'_{i,C} \beta_C + \mathbf{X}'_{i,B} \beta_B + \varepsilon_i, \\ M_5 : Y_i &= \alpha_5 + \mathbf{X}'_{i,D} \beta_D + \mathbf{X}'_{i,F} \beta_F + \mathbf{X}'_{i,C} \beta_C + \mathbf{X}'_{i,B} \beta_B + \mathbf{X}'_{i,J} \beta_J + \varepsilon_i. \end{aligned}$$

En esta notación, D corresponde al bloque demográfico, F al bloque familiar y socioeconómico, C al bloque cognitivo, B al bloque de conducta pasada, y J al bloque de justicia y sustancias. En términos de

variables, M_1 incluye sexo, raza o etnicidad, edad de la madre biológica y número de hermanos. M_2 agrega estructura familiar, educación parental y razón ingreso-pobreza en 1997. M_3 agrega el puntaje ASVAB. M_4 incorpora los conteos de conducta pasada entre los 14 y los 17 años: destrucción de propiedad, robo menor a 50 dólares, robo mayor a 50 dólares, otros delitos contra propiedad, presencia o contacto con pandillas, portación de arma y huida del hogar. M_5 agrega consumo de tabaco, alcohol, marihuana, drogas duras y arresto antes de los 18 años. Este último es el modelo lineal principal porque contiene todos los predictores preadultos definidos en el análisis. También se estima M_6 , que añade las interacciones FEMALE_x_BLACK y FEMALE_x_HISPANIC; ese modelo se trata como una extensión.

Para evaluar si cada bloque añade información predictiva al bloque anterior, se usa una prueba F incremental entre modelos anidados. Para comparar un modelo reducido r contra un modelo amplio a , el estadístico es

$$F = \frac{(RSS_r - RSS_a)/(df_r - df_a)}{RSS_a/df_a},$$

donde RSS_r y RSS_a son las sumas de cuadrados residuales del modelo reducido y del modelo amplio, respectivamente, y $df_r - df_a$ es el número de predictores añadidos. La hipótesis nula es que todos los coeficientes del bloque agregado son iguales a cero. Además, se reportan R^2 , R^2 ajustada, AIC y BIC. La evaluación fuera de muestra se realiza únicamente para M_5 . La muestra se divide en 85 por ciento de entrenamiento y 15 por ciento de prueba, con estratificación por Y_i . El modelo se estima sólo con el conjunto de entrenamiento y luego se predice sobre entrenamiento y prueba. Con esas predicciones se calculan R^2 , RMSE, MAE, accuracy con umbral 0.5 y AUC. El AUC recibe más peso interpretativo porque resume la capacidad de ordenar correctamente casos positivos y negativos sin depender del umbral de clasificación.

El segundo componente es un random forest de clasificación entrenado sobre los mismos 26 predictores. La muestra se divide en 85 por ciento de entrenamiento y 15 por ciento de prueba, con estratificación por la variable dependiente. El modelo usa 500 árboles, selección aleatoria de $\sqrt{p}$ variables candidatas en cada división, mínimo de 10 observaciones por hoja, pesos balanceados por clase, estimación out-of-bag, semilla 42 y todos los núcleos disponibles para entrenamiento. La métrica principal vuelve a ser el AUC en la muestra de prueba. El random forest permite relaciones no lineales e interacciones entre predictores sin especificarlas una por una, pero por sí solo es menos transparente que el modelo lineal.

La importancia por permutación de bloques se calcula sobre el conjunto de prueba. Para cada bloque B_k , el análisis permuta simultáneamente todas sus columnas, predice de nuevo y calcula la caída en AUC:

$$BPI(B_k) = AUC(f, D) - AUC(f, D_{B_k}^{perm}).$$

El procedimiento se repite 100 veces por bloque. En cada repetición se reordenan conjuntamente las columnas del bloque con el mismo índice aleatorio. Por eso se conserva la estructura interna del bloque, pero se rompe su relación con el resultado y con el resto de los predictores. Se reporta la media de la caída, su desviación estándar y el intervalo empírico de 95 por ciento. Esta medida se interpreta como cuánto pierde el modelo cuando ya no puede usar la información de ese bloque, manteniendo intactos los demás bloques.

4 Resultados

Los resultados muestran que la señal predictiva no se distribuye de manera uniforme entre bloques. En el modelo lineal, el bloque demográfico por sí solo alcanza una R^2 ajustada de 0.034. Agregar familia y nivel socioeconómico la eleva a 0.040, y agregar ASVAB apenas la mueve a 0.041. El salto principal ocurre al incorporar conducta pasada: la R^2 ajustada sube a 0.096 y el incremento de R^2 no ajustada es 0.056. El bloque final de justicia y sustancias aumenta la R^2 ajustada a 0.102. La extensión con interacciones sexo por raza llega a 0.103, pero la prueba incremental tiene $p = 0.084$, por lo que el modelo preferido sigue siendo M_5 .

La lectura por variables dentro del modelo M_5 confirma que no todos los bloques aportan del mismo modo. En el bloque demográfico, ser mujer se asocia con una probabilidad 7.2 puntos porcentuales menor de reportar agresión adulta, manteniendo constantes los demás predictores, mientras que la categoría Black se asocia con 7.0 puntos porcentuales adicionales respecto a la categoría de referencia. En el bloque familiar y socioeconómico, la educación parental de preparatoria tiene un coeficiente negativo de 4.5 puntos, pero la estructura familiar y el ingreso pierden precisión una vez que entran las conductas adolescentes. El bloque cognitivo también se debilita: ASVAB aporta cuando entra solo como tercer bloque, pero su coeficiente deja de ser distinguible de cero en M_5 .

El bloque de conducta pasada es el más consistente en el modelo lineal. Cada año adicional en que la persona reportó destrucción de propiedad entre los 14 y los 17 años se asocia con 3.6 puntos porcentuales más de probabilidad de agresión adulta. Presencia o contacto con pandillas se asocia con 3.8 puntos por año, portación de arma con 4.7 puntos por año y haber huido del hogar con 5.9 puntos por año. En cambio, los indicadores de robo menor, robo mayor y otros delitos contra propiedad no muestran una señal tan clara en el modelo completo. En el bloque de justicia y sustancias, las variables más importantes son haber sido arrestado antes de los 18 años, con 7.4 puntos porcentuales adicionales, y consumo de marihuana, con 2.2 puntos por año. Tabaco, alcohol y drogas duras no son estadísticamente distinguibles de cero en M_5 .

La comparación entre modelos refuerza el mismo patrón, pero muestra un intercambio entre interpretabilidad y desempeño predictivo. La validación fuera de muestra del modelo lineal M_5 muestra una capacidad moderada: en entrenamiento, el AUC es 0.764 y el R^2 es 0.119; en prueba, con 561 personas, el AUC baja a 0.682 y el R^2 a 0.036. La accuracy con umbral de 0.5 es 0.854 en prueba, pero esta métrica es menos informativa que el AUC porque depende de un punto de corte fijo.

El random forest mejora la discriminación fuera de muestra. Su AUC de prueba es 0.727, con AUC out-of-bag de 0.747 y AUC de entrenamiento de 0.928. La diferencia entre entrenamiento y prueba indica sobreajuste residual, aunque la métrica de prueba sigue por encima del modelo lineal. La importancia por permutación de bloques reproduce el ordenamiento central del análisis lineal. Permutar el bloque de conducta pasada reduce el AUC en 0.088 en promedio. El bloque demográfico reduce el AUC en 0.058 y el bloque de justicia y sustancias en 0.030. Familia y nivel socioeconómico tiene una caída media de 0.016, mientras que el bloque cognitivo tiene una caída cercana a cero y un intervalo que cruza cero. El random forest sólo mide importancia por bloque, por lo que las variables individuales más relevantes deben leerse desde el modelo lineal, no desde el procedimiento de permutación.

La implicación para ciencia de datos aplicada a política pública es que el valor predictivo está concentrado en señales observables durante la adolescencia, no en un solo atributo fijo. Para investigación futura, esto sugiere validar el ordenamiento en otras muestras, revisar calibración, examinar desempeño por subgrupos y diseñar estudios causales que separen predicción de mecanismos. Para la práctica clínica o institucional, la lectura prudente es de tamizaje y priorización de apoyo: presencia o contacto con pandillas, portación de arma, huida del hogar, destrucción de propiedad, consumo de marihuana y arresto temprano pueden activar evaluación profesional y seguimiento preventivo. No deben usarse como diagnóstico automático, sanción anticipada ni perfil rígido de riesgo.

5 Conclusión

El hallazgo principal es que la información conductual de la adolescencia es el predictor más fuerte de agresión física reportada en la adultez joven. Esta conclusión aparece tanto en el modelo de probabilidad lineal jerárquico como en el random forest con importancia por permutación de bloques. La robustez entre métodos importa porque el primer modelo es fácil de interpretar, mientras que el segundo permite relaciones no lineales e interacciones sin imponerlas de forma explícita.

Para política pública, el resultado apunta a la utilidad de sistemas de prevención que observen conductas concretas durante la adolescencia. En particular, presencia o contacto con pandillas, portación de arma, huida del hogar, destrucción de propiedad, consumo de marihuana y arresto temprano aparecen como señales relevantes dentro del modelo final. La política pública no debería leer estos resultados como una justificación para castigos automáticos o perfiles rígidos. Una interpretación más prudente es que esos eventos pueden servir para activar apoyos, seguimiento y programas preventivos antes de que la trayectoria llegue a la adultez.

El trabajo también muestra límites importantes. El resultado depende de autorreportes de agresión, por lo que puede haber subregistro o diferencias en disposición a responder. La muestra analítica se reduce a personas con información completa en todas las variables, lo cual puede afectar la representatividad. Además, el diseño no identifica causalidad. Aun así, la separación temporal entre predictores y resultado, el uso de la misma muestra para ambos métodos y la comparación por bloques hacen que el ordenamiento predictivo sea claro: las variables más próximas a la conducta adolescente explican más que los bloques distales.

6 Anexo: tablas y figuras

Table 1: Estadísticos descriptivos de variables seleccionadas en la muestra analítica. $n = 3,737$.

Variable	Media	DE	Mín.	Máy.
Agresión adulta	0.143	0.350	0	1
Mujer	0.493	0.500	0	1
Black	0.220	0.414	0	1
Hispanic	0.182	0.386	0	1
Edad madre biol.	25.697	5.267	12	52
Núm. hermanos	1.556	1.190	0	9
Razón ingreso-pobreza	2.976	2.709	0	16.27
ASVAB	47.976	29.107	0	100
Contacto pandillas, 14-17	0.560	0.678	0	4
Portó arma, 14-17	0.161	0.468	0	4
Arresto antes de 18	0.134	0.340	0	1

Table 2: Ajuste de modelos de probabilidad lineal jerárquicos. Todos usan la misma muestra analítica.

Modelo	Bloque	Pred.	R^2 aj.	AIC	BIC
M1	Demográfico	6	0.034	2641.9	2685.5
M2	Familia/SES	13	0.040	2625.6	2712.8
M3	ASVAB	14	0.041	2623.5	2716.9
M4	Conducta	21	0.096	2411.2	2548.1
M5	Justicia/sust.	26	0.102	2389.4	2557.5
M6	Interacciones	28	0.103	2388.4	2568.9

Table 3: Pruebas F incrementales entre modelos anidados.

Transición	Bloque	ΔR^2	F	gl	p
M1 a M2	Familia/SES	0.0078	4.33	7, 3723	< 0.001
M2 a M3	Cognitivo	0.0011	4.13	1, 3722	0.042
M3 a M4	Conducta	0.0561	33.13	7, 3715	< 0.001
M4 a M5	Justicia/sust.	0.0076	6.34	5, 3710	< 0.001
M5 a M6	Interacciones	0.0012	2.48	2, 3708	0.084

Table 4: Coeficientes seleccionados del modelo $M5$. Las conductas son conteos de años entre los 14 y los 17 años, salvo arresto, que es binario.

Variable	Coef.	EE HC1	p	IC 95%
Mujer	-0.072	0.011	< 0.001	[-0.094, -0.049]
Black	0.070	0.017	< 0.001	[0.036, 0.104]
Núm. hermanos	-0.010	0.005	0.036	[-0.019, -0.001]
Educ. parental: prep.	-0.045	0.020	0.027	[-0.085, -0.005]
Destr. propiedad	0.036	0.011	0.001	[0.015, 0.058]
Contacto pandillas	0.038	0.009	< 0.001	[0.020, 0.056]
Portó arma	0.047	0.016	0.004	[0.015, 0.079]
Huyó del hogar	0.059	0.017	0.001	[0.025, 0.093]
Marihuana	0.022	0.010	0.029	[0.002, 0.043]
Arresto <18	0.074	0.023	0.002	[0.028, 0.119]

Table 5: Validación fuera de muestra. El random forest reporta AUC en el conjunto de prueba.

Métrica	Train M5	Test M5	RF test
n	3,176	561	561
AUC	0.764	0.682	0.727
R^2	0.119	0.036	No aplica
RMSE	0.329	0.343	No aplica
Accuracy, umbral 0.5	0.858	0.854	No reportada

Table 6: Importancia por permutación de bloques en el random forest. El AUC base de prueba es 0.7271.

Bloque	Caída AUC	DE	IC 95%
Conducta pasada	0.0884	0.0216	[0.0437, 0.1275]
Demográfico	0.0577	0.0148	[0.0289, 0.0861]
Justicia/sust.	0.0302	0.0156	[0.0013, 0.0589]
Familia/SES	0.0161	0.0079	[0.0009, 0.0303]
Cognitivo	0.0026	0.0071	[-0.0099, 0.0156]




Figure 1: R^2 ajustada por modelo jerárquico.

Diagnóstico del modelo final (M5)




Figure 2: Diagnósticos del modelo final $M5$.




Figure 3: Predicciones contra valores observados en el conjunto de prueba del modelo $M5$.




Figure 4: Coeficientes seleccionados del modelo $M5$ con intervalos de confianza robustos.




Figure 5: Importancia por permutación de bloques en el random forest.




Figure 6: Curva ROC del random forest en el conjunto de prueba.




Figure 7: Distribución de las caídas de AUC por bloque en 100 permutaciones.




Figure 8: Comparación de importancia relativa por bloque entre el modelo lineal y el random forest.

Referencias

Breiman, Leo. 2001. “Random Forests.” *Machine Learning* 45(1): 5–32.

Molnar, Christoph. 2022. *Interpretable Machine Learning*. Self-published.

Strobl, Carolin, Anne-Laure Boulesteix, Thomas Kneib, Thomas Augustin, and Achim Zeileis. 2008. “Conditional Variable Importance for Random Forests.” *BMC Bioinformatics* 9: 307.

United States Department of Justice, Office of Justice Programs, Bureau of Justice Statistics. 2014. “Recidivism in the National Longitudinal Survey of Youth 1997: Standalone Data, Rounds 1 to 13.” doi:[10.3886/ICPSR34562.v1](https://doi.org/10.3886/ICPSR34562.v1).