

Determinantes individuales y de contexto de la violencia interpersonal en jóvenes estadounidenses: un modelo lineal jerárquico sobre el NLSY97

Jerónimo Deli
Tópicos de Políticas Públicas II
ITAM, Primavera 2026

May 26, 2026

Abstract

Este trabajo estudia los determinantes individuales, familiares, cognitivos y conductuales de haber reportado al menos una agresión física entre los 14 y los 25 años. La evidencia proviene del *National Longitudinal Survey of Youth 1997* (NLSY97), enriquecido con variables de justicia penal por el Bureau of Justice Statistics. La estrategia empírica es un *Linear Probability Model* estimado por mínimos cuadrados ordinarios con errores estándar robustos a heterocedasticidad (HC1). Para aislar la contribución relativa de cada dominio se ajusta una secuencia jerárquica de seis modelos en la que se añaden, de manera incremental, bloques de variables demográficas, familiares y socioeconómicas, cognitivas, de conducta delictiva temprana y de sustancias/justicia, hasta una especificación con interacciones sexo $\times$ raza. Los modelos se comparan con ANOVA incremental, R^2 ajustada, AIC y BIC, y se validan fuera de muestra con una partición 85/15. Los resultados muestran que la conducta delictiva en la adolescencia temprana y el arresto previo a los 18 años absorben la mayor parte del poder predictivo, sin anular las brechas asociadas al sexo, la raza y el contexto familiar.

Contents

1	Introducción al problema	3
2	Resumen del análisis estadístico	3
3	Marco teórico	4
4	Análisis de datos	5
4.1	Descripción de la base	5
4.2	Variables utilizadas	6
4.3	Estadísticas descriptivas numéricas	7
4.4	Estadísticas descriptivas categóricas	7
4.5	Análisis exploratorio	8
5	Pruebas ANOVA	10
6	Ajuste de modelos	10
6.1	Coefficientes estimados	13
6.2	Comparación de ajuste	14
6.3	ANOVA incremental	15
7	Especificación del modelo base	16
8	Validación fuera de muestra (85/15)	16
9	Diagnóstico	17
10	Conclusión	19
11	Referencias	20

1 Introducción al problema

La violencia interpersonal en adolescentes y jóvenes adultos es una de las preocupaciones más persistentes de la política social en Estados Unidos. Más allá del costo humano, las agresiones entre pares tienen consecuencias documentadas sobre el desempeño escolar, la trayectoria laboral, la salud mental y la probabilidad de contacto futuro con el sistema penal. La política pública dispone de un repertorio amplio de intervenciones para enfrentar el problema —prevención escolar, programas de mentoría, terapia cognitivo-conductual, tribunales de drogas juveniles, mediación restaurativa— pero todas comparten una restricción presupuestal estricta y deben dirigirse a quienes más se benefician de ellas. Para diseñarlas y focalizarlas con eficacia es necesario entender qué factores observables *en la adolescencia temprana* predicen una mayor probabilidad de incurrir en agresión física a lo largo del ciclo de vida juvenil, y cuáles de esos factores son redundantes una vez que se controla por los demás.

La pregunta es difícil porque la conducta agresiva no surge de un único origen. Los determinantes plausibles se distribuyen en al menos cinco dominios distintos: características demográficas estables (sexo, raza/etnicidad, edad de la madre al nacer), contexto familiar y socioeconómico (estructura del hogar, educación de los padres, razón ingreso-pobreza), capacidad cognitiva (medida con instrumentos estandarizados como el ASVAB), conductas de riesgo en la adolescencia temprana (vandalismo, robos, pertenencia a pandillas, porte de armas, fugarse de casa) y consumo de sustancias junto con el contacto temprano con el sistema penal (alcohol, tabaco, marihuana, drogas duras y arresto antes de los 18 años). Una buena política pública requiere entender no sólo cuáles de estos dominios importan, sino cuánto importa cada uno *cuando se controla por los demás*.

Para responder esta pregunta usamos el *National Longitudinal Survey of Youth 1997* (NLSY97), una encuesta panel del Bureau of Labor Statistics que sigue desde 1997 a una cohorte representativa de jóvenes estadounidenses nacidos entre 1980 y 1984. El subconjunto utilizado (ICPSR 34562) fue construido por el Bureau of Justice Statistics combinando los reportes anuales de conducta del propio respondente con información administrativa de arrestos, condenas y encarcelamientos. La cohorte fue entrevistada anualmente entre los 14 y los 25 años de edad, lo que ofrece una ventana razonable para observar la trayectoria juvenil completa.

Las preguntas de investigación centrales son:

1. **¿Qué bloques de información sobre un joven en la adolescencia temprana predicen la probabilidad de haber reportado al menos una agresión física entre los 14 y los 25 años?**
2. **¿Cuánto poder explicativo adicional aporta cada dominio (demográfico, familiar y socioeconómico, cognitivo, conductual, de sustancias y justicia) por encima de los anteriores?**
3. **¿Persisten las brechas demográficas y de contexto familiar después de controlar por conducta temprana y arresto previo a los 18 años?**
4. **¿La asociación entre sexo y agresión cambia según la raza/etnicidad?**

2 Resumen del análisis estadístico

El flujo del análisis sigue estos pasos:

1. Definición de la variable dependiente `EVER_ASSAULT` a partir de los reportes anuales `ASSAULT_CY{n}`.
2. Construcción de una muestra analítica con observaciones completas en todas las variables explicativas.
3. Análisis exploratorio con tablas descriptivas y gráficas.
4. Pruebas ANOVA univariadas para comparar la prevalencia entre grupos.
5. Ajuste de seis modelos lineales en complejidad creciente.
6. Comparación formal con ANOVA incremental, R^2 ajustada, AIC y BIC.
7. Diagnósticos del modelo final: residuos, Q-Q plot, scale-location, leverage y prueba de Breusch-Pagan.
8. Validación fuera de muestra con partición aleatoria 85% / 15%.

3 Marco teórico

La herramienta principal del proyecto es el modelo lineal jerárquico estimado por mínimos cuadrados ordinarios (OLS). Dado que la variable dependiente es binaria (1 = reportó al menos una agresión entre los 14 y 25 años, 0 = nunca lo reportó), el modelo se interpreta como un *Linear Probability Model* (LPM):

$$P(Y_i = 1 \mid X_i) = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \cdots + \beta_k X_{ik} + u_i,$$

donde Y_i es `EVER_ASSAULT`, los términos X recogen características observadas del joven y u_i resume factores no observados. Bajo esta especificación cada coeficiente β_j se interpreta directamente como el cambio en la probabilidad estimada de agresión asociado a un cambio unitario en la variable explicativa, manteniendo constantes las demás. Esta interpretación es atractiva para política pública porque las magnitudes están en la misma escala que la variable de interés (puntos porcentuales).

El LPM tiene tres ventajas conocidas frente a alternativas no lineales como logit o probit. Primero, los coeficientes son directamente interpretables como efectos marginales, sin necesidad de evaluar derivadas en distintos puntos del espacio de covariables. Segundo, las comparaciones entre modelos anidados pueden realizarse con la maquinaria estándar de OLS: ANOVA incremental, R^2 , AIC y BIC. Tercero, los errores estándar robustos a heterocedasticidad (HC1) corrigen el principal problema técnico del LPM, que es que la varianza de u_i depende del valor esperado de Y_i y por construcción no es constante. En este trabajo toda la inferencia se hace con errores estándar HC1, calculados a partir de la matriz *sandwich* de White.

Las limitaciones también son conocidas y se discuten más adelante: las probabilidades predichas pueden caer fuera del intervalo $[0, 1]$, y la prueba de Breusch-Pagan rechaza formalmente la hipótesis de homocedasticidad. El uso de errores estándar HC1 atiende lo segundo; la primera limitación se asume conscientemente a cambio de la transparencia interpretativa que ofrece el LPM, y se acompaña, en la sección de validación, con métricas de clasificación (*accuracy* y AUC) que no dependen del supuesto de probabilidad acotada.

La organización jerárquica del modelo merece una explicación aparte. En lugar de estimar una sola especificación con todas las variables, se ajusta una secuencia anidada de seis modelos. Cada modelo añade un bloque temático coherente al anterior. Esta estrategia permite responder dos preguntas que un modelo único no puede contestar: (i) cuánta varianza explica cada dominio por sí solo, y

(ii) cuánta varianza adicional aporta un dominio nuevo *una vez que se controla por los anteriores*. Si una variable parece importante en aislamiento y desaparece al añadir un bloque posterior, ese bloque está capturando el mismo mecanismo. La ANOVA incremental cuantifica formalmente este aporte.

El uso de variables dummy es central. Variables categóricas como la raza/etnicidad, la estructura familiar o la educación de los padres se incorporan mediante indicadores binarios que comparan cada categoría con una de referencia. Esto permite estimar diferencias promedio entre grupos sin imponer una estructura lineal artificial sobre lo que son categorías discretas. Las interacciones se construyen multiplicando dos dummies (por ejemplo, `FEMALE × RACE_BLACK`), y su coeficiente captura el cambio en la asociación de una variable cuando la otra está presente.

4 Análisis de datos

4.1 Descripción de la base

Los datos provienen del *Recidivism in the National Longitudinal Survey of Youth 1997* (ICPSR 34562, archivo DS0001, $N = 8,984$ respondentes y 392 variables). El archivo combina información sociodemográfica medida una sola vez en 1997 con seguimientos anuales entre los 14 y los 23 años. Para cada año de vida del respondente se registran indicadores binarios de conducta delictiva (`ASSAULT_CY{n}`, `DESTROY_CY{n}`, etc.), de consumo de sustancias y de contacto con el sistema penal. Las variables del NLSY97 utilizan códigos especiales (`Non-interview`, `Refused`, `Don't know`, `Valid missing`) que en este análisis se tratan como faltantes antes de cualquier cálculo numérico.

La variable dependiente `EVER_ASSAULT` se construye colapsando los reportes anuales `ASSAULT_CY14` a `ASSAULT_CY23`: vale 1 si el respondente reportó al menos una agresión física intencional en cualquier año observado y 0 si reportó *No* en todos los años con respuesta válida. Para evitar *data leakage*, las variables de agresión se excluyen completamente del conjunto de predictores; en su lugar se construyen agregados de *otras* conductas delictivas y de sustancias restringidos al tramo **14–17 años** (adolescencia temprana). Esto garantiza que los predictores son anteriores o contemporáneos al inicio del riesgo medido, no posteriores.

La muestra analítica se obtiene exigiendo información válida en todas las variables que entran a los seis modelos, lo que asegura comparabilidad entre especificaciones. El resultado son $N = 3,815$ **jóvenes**, equivalentes al 42.5% de la muestra original. La principal fuente de atrición proviene de `POVRATIO97` (27% de faltantes) y `ASVAB_SCORE` (21% de faltantes); se discute la posible selectividad en la sección de limitaciones.

4.2 Variables utilizadas

Table 1: Variables principales del proyecto

columna	tipo	definición corta	uso en proyecto
EVER_ASSAULT	binaria	=1 si reportó ≥ 1 agresión entre 14 y 25 años	Dependiente
FEMALE	binaria	=1 si sexo = mujer	Demográfico
RACE_BLACK, RACE_HISPANIC, RACE_MIXED	binarias	raza/etnicidad (ref = no-Black/no-Hispanic)	Demográfico
BIOMOMAGE	numérica	edad de la madre al nacer el respondente	Demográfico
NUMSIBS	numérica	número de hermanos en 1997	Demográfico
FAM_ONE_PARENT, FAM_BIO_STEP, FAM_OTHER	binarias	estructura familiar (ref = dos padres biológicos)	Familia/SES
PAR_ED_HS, PAR_ED_SOME_COL, PAR_ED_COL	binarias	educación máxima de los padres (ref = <HS)	Familia/SES
POVRATIO97	numérica	razón ingreso del hogar / línea de pobreza en 1997	Familia/SES
ASVAB_SCORE	numérica	percentil ASVAB (habilidad cognitiva)	Cognitivo
EARLY_DESTROY, EARLY_STEAL_*, EARLY_OTHER_PROP, EARLY_GANG, EARLY_GUN, EARLY_RUNAWAY	numéricas (conteo)	número de años 14–17 con reporte afirmativo	Conducta pasada
EARLY_SMOKING, EARLY_ALCOHOL, EARLY_MARIJUANA, EARLY_HARD_DRUGS	numéricas (conteo)	número de años 14–17 con consumo afirmativo	Justicia/Sustancias
EVER_ARR_BY17	binaria	=1 si reportó arresto en cualquier año 14–17	Justicia/Sustancias

La Tabla 1 organiza las variables en los cinco bloques temáticos que definen la secuencia jerárquica de modelos. Las variables de conducta y sustancias se construyen como conteos restringidos al tramo 14–17 años: si un respondente reportó pertenencia a una pandilla cuando tenía 14 y 15 años pero no a los 16 ni 17, `EARLY_GANG` = 2. Este diseño preserva la intensidad de la exposición y respeta el orden temporal respecto a la variable dependiente, que cubre hasta los 25 años.

4.3 Estadísticas descriptivas numéricas

Table 2: Resumen de variables numéricas en la muestra analítica

variable	n	media	desv. est.	mediana
BIOMOMAGE	3,815	25.70	5.26	25.00
NUMSIBS	3,815	1.55	1.19	1.00
POVRATIO97	3,815	2.98	2.70	2.45
ASVAB_SCORE	3,815	47.88	29.09	46.59

La Tabla 2 reporta las cuatro variables continuas del modelo. La edad mediana de la madre al nacer el respondente es de 25 años. El número mediano de hermanos es uno. La razón ingreso/pobreza tiene una media de 2.98, lo que indica que un hogar promedio de la muestra tenía un ingreso casi tres veces la línea de pobreza federal en 1997; la mediana (2.45) es menor que la media, consistente con la asimetría hacia la derecha típica de la distribución del ingreso. El puntaje ASVAB tiene media 47.9 y desviación estándar 29.1, lo que confirma que recorre prácticamente todo el rango 0–100.

4.4 Estadísticas descriptivas categóricas

Table 3: Distribución de variables categóricas en la muestra analítica

bloque	categoría	n	prop.
Sexo	Hombre (ref)	1,934	50.7%
	Mujer (FEMALE=1)	1,881	49.3%
Raza/etnicidad	No-Black/No-Hispanic (ref)	2,258	59.2%
	Black	833	21.8%
	Hispanic	692	18.1%
	Mixed	32	0.8%
Estructura familiar	Dos padres biológicos (ref)	2,116	55.5%
	Un solo padre/madre	1,153	30.2%
	Biológico + padrastro/madrastra	520	13.6%
	Otra	26	0.7%
Educación de los padres	Menos de preparatoria (ref)	540	14.2%
	Preparatoria	1,168	30.6%
	Algo de universidad	1,071	28.1%
	Título universitario o más	1,036	27.2%
Prevalencia de EVER_ASSAULT		1,161	30.4%
Arresto reportado antes de los 18 años		509	13.3%

La Tabla 3 muestra que la muestra está balanceada por sexo. La población no-Black/no-Hispanic representa el grupo mayoritario (59.2%), seguida por Black (21.8%) e Hispanic (18.1%). Más de la mitad de los respondentes vivían en hogares con ambos padres biológicos en 1997, mientras que el 30% vivía con un solo padre. La distribución de la educación de los padres es bastante uniforme entre los tres tramos altos, con sólo 14% de los padres con menos de preparatoria. El 30.4% de los respondentes reportó al menos una agresión física entre los 14 y los 25 años (la variable dependiente del estudio), y el 13.3% había sido arrestado al menos una vez antes de los 18 años.

4.5 Análisis exploratorio




Figure 1: Distribución de la variable dependiente EVER_ASSAULT en la muestra analítica.

Interpretación: La clase positiva (haber reportado al menos una agresión) cubre el 30.4% de la muestra; la negativa, el 69.6%. Hay desbalance moderado pero no extremo: ambos grupos tienen suficiente masa para que el modelo lineal estime coeficientes estables sin necesidad de re-ponderar las observaciones.




Figure 2: Prevalencia de EVER_ASSAULT por sexo y por raza/etnicidad.

Interpretación: La prevalencia es notablemente mayor entre hombres (37.6%) que entre mujeres (23.1%). Por raza/etnicidad, el grupo Black registra la prevalencia más alta (40.6%), seguido por Mixed (34.4%), Hispanic (30.6%) y, por último, no-Black/no-Hispanic (26.6%). Estas brechas motivan la inclusión de ambas variables en el bloque demográfico.




Figure 3: Prevalencia de EVER_ASSAULT por decil de puntaje ASVAB.

Interpretación: Existe un gradiente monótono descendente de la prevalencia de agresión a medida que aumenta el percentil ASVAB. El decil más bajo presenta una prevalencia cercana al 40%, mientras que el decil más alto se ubica por debajo del 20%. Esto sugiere que la habilidad cognitiva medida en la adolescencia capta un componente relevante del riesgo.




Figure 4: Prevalencia de EVER_ASSAULT según conductas de riesgo en adolescencia temprana (14–17 años).

Interpretación: Las tres conductas reportadas en la figura muestran asociaciones muy fuertes con la agresión observada en el panel completo. Quienes nunca pertenecieron a una pandilla en la adolescencia temprana tienen una prevalencia de agresión cercana al 20%; entre quienes sí pertenecieron, la prevalencia supera el 40%. El mismo patrón aparece para porte de armas y consumo de drogas duras. Estas asociaciones univariadas anticipan que el bloque de conducta pasada será el de mayor poder explicativo en el modelo multivariado.

5 Pruebas ANOVA

El análisis de varianza (ANOVA) compara la media de una variable continua (en este caso, `EVER_ASSAULT`, que toma valores 0 y 1) entre los grupos definidos por una variable categórica. La hipótesis nula sostiene que todas las medias son iguales; la alternativa, que al menos una difiere. El estadístico F compara la varianza entre grupos con la varianza dentro de grupos: un F alto y un valor p pequeño señalan que las diferencias entre grupos son sistemáticas. Estas pruebas se usan como una primera validación: si una variable categórica no muestra diferencias significativas, es poco probable que aporte poder explicativo en una regresión multivariada.

Table 4: Pruebas ANOVA univariadas de `EVER_ASSAULT`

factor	F	p	número de grupos
Sexo	97.30	< 0.001	2
Raza/etnicidad	19.14	< 0.001	4
Educación de los padres	17.92	< 0.001	4

Las tres ANOVA univariadas reportadas en la Tabla 4 rechazan la hipótesis nula de medias iguales con $p < 0.001$. La prevalencia de agresión difiere de manera sistemática entre hombres y mujeres, entre grupos raciales y entre tramos de educación de los padres, lo que justifica incluir las tres variables en la especificación multivariada.

6 Ajuste de modelos

Table 5: Guía de lectura de los modelos estimados

Modelo	Variables agregadas respecto al anterior	Bloque	Papel en el análisis
Modelo 1	sexo, raza, edad madre, hermanos	Demográfico	Punto de partida
Modelo 2	estructura familiar, educación de padres, ratio pobreza	+ Familia y SES	Mejora incremental
Modelo 3	puntaje ASVAB	+ Cognitivo	Mejora incremental
Modelo 4	conducta delictiva 14–17 (vandalismo, robos, pandilla, arma, fuga)	+ Conducta pasada	Mejora incremental
Modelo 5	sustancias 14–17 y arresto antes de los 18 años	+ Justicia/Sustancias	Modelo base principal
Modelo 6	interacciones FEMALE×BLACK y FEMALE×HISPANIC	+ Interacción sexo×raza	

La Tabla 5 resume la lógica de construcción. Cada modelo añade un bloque temático coherente al anterior y se interpreta como una hipótesis incremental sobre los determinantes de la agresión juvenil. El Modelo 1 contesta la pregunta: *¿qué tanto explican las características demográficas estables por sí solas?*. El Modelo 2 añade el contexto familiar y socioeconómico medido en 1997. El

Modelo 3 introduce la habilidad cognitiva. El Modelo 4 incorpora la conducta delictiva temprana, que es el bloque sustantivo más cercano a la variable dependiente. El Modelo 5 añade el bloque de sustancias y la variable de arresto antes de los 18 años. Finalmente, el Modelo 6 explora si la asociación entre sexo y agresión cambia según la raza/etnicidad.

6.1 Coeficientes estimados

Table 6: Coeficientes estimados (LPM, OLS con errores HC1) de los seis modelos

	M1	M2	M3	M4	M5	M6
(Intercepto)	0.540*** (0.042)	0.479*** (0.050)	0.540*** (0.051)	0.332*** (0.047)	0.268*** (0.047)	0.262*** (0.047)
Mujer	-0.151*** (0.015)	-0.152*** (0.014)	-0.145*** (0.014)	-0.087*** (0.014)	-0.085*** (0.014)	-0.074*** (0.016)
Raza: Black	0.130*** (0.019)	0.082*** (0.021)	0.042* (0.021)	0.073*** (0.020)	0.106*** (0.020)	0.124*** (0.028)
Raza: Hispanic	0.038+ (0.020)	0.002 (0.021)	-0.019 (0.021)	-0.018 (0.020)	-0.006 (0.019)	0.003 (0.028)
Raza: Mixed	0.077 (0.085)	0.071 (0.087)	0.081 (0.083)	0.069 (0.081)	0.063 (0.077)	0.062 (0.077)
Edad madre	-0.008*** (0.001)	-0.004** (0.002)	-0.004* (0.002)	-0.003+ (0.001)	-0.003* (0.001)	-0.003* (0.001)
N. ^o hermanos	0.001 (0.006)	0.000 (0.007)	-0.001 (0.007)	-0.001 (0.006)	0.002 (0.006)	0.002 (0.006)
Familia: 1 padre		0.102*** (0.018)	0.098*** (0.018)	0.056*** (0.017)	0.041* (0.016)	0.040* (0.016)
Familia: bio+pad.		0.080*** (0.023)	0.068** (0.023)	0.037+ (0.021)	0.020 (0.021)	0.020 (0.021)
Familia: otra		0.174+ (0.102)	0.148 (0.101)	0.166+ (0.095)	0.161+ (0.097)	0.160+ (0.097)
Padres ed.: HS		-0.038 (0.026)	-0.020 (0.026)	-0.020 (0.023)	-0.018 (0.023)	-0.018 (0.023)
Padres ed.: SC		-0.029 (0.026)	0.005 (0.027)	-0.012 (0.024)	-0.006 (0.024)	-0.006 (0.024)
Padres ed.: Col		-0.084** (0.028)	-0.029 (0.029)	-0.039 (0.026)	-0.027 (0.026)	-0.027 (0.026)
Ratio pobreza		-0.005+ (0.003)	-0.002 (0.003)	-0.002 (0.003)	-0.003 (0.003)	-0.003 (0.003)
ASVAB			-0.0021*** (0.0003)	-0.0016*** (0.0003)	-0.0013*** (0.0003)	-0.0013*** (0.0003)
Vandalismo (14-17)				0.117*** (0.012)	0.101*** (0.012)	0.102*** (0.012)
Robo <\$50 (14-17)				0.040*** (0.012)	0.010 (0.012)	0.011 (0.012)
Robo ≥\$50 (14-17)				0.041+ (0.021)	0.015 (0.021)	0.015 (0.021)
Otro c. propiedad				0.071*** (0.021)	0.055** (0.021)	0.055** (0.021)
Pandilla (14-17)				0.076*** (0.011)	0.067*** (0.011)	0.067*** (0.011)
Portó arma (14-17)				0.063*** (0.017)	0.047** (0.017)	0.048** (0.017)
Huyó de casa (14-17)				0.138*** (0.018)	0.091*** (0.018)	0.091*** (0.018)
Tabaco (14-17)					0.032*** (0.007)	0.032*** (0.007)
Alcohol (14-17)					0.008 (0.007)	0.008 (0.007)
Mariguana (14-17)					0.017 (0.012)	0.017 (0.012)
Drogas duras (14-17)					0.029 (0.019)	0.029 (0.020)
Arresto antes de 18					0.172*** (0.024)	0.171*** (0.025)
Mujer × Black						-0.036 (0.035)
Mujer × Hispanic						-0.017 (0.034)
N	3,815	3,815	3,815	3,815	3,815	3,815
R ²	0.049	0.066	0.078	0.235	0.265	0.265
R ² ajustada	0.047	0.063	0.074	0.231	0.260	0.260

+ $p < 0.1$; * $p < 0.05$; ** $p < 0.01$; *** $p < 0.001$. Errores estándar HC1 entre paréntesis.

La Tabla 6 reporta los coeficientes de los seis modelos lado a lado. Como cada coeficiente representa un cambio en *probabilidad*, las magnitudes se leen directamente en puntos porcentuales. Hay varios patrones que conviene destacar antes de comparar formalmente el ajuste.

Primero, el coeficiente de **Mujer** disminuye de -0.151 en el Modelo 1 a -0.085 en el Modelo 5 (una caída cercana a la mitad), pero permanece estadísticamente significativo. Esto indica que parte de la brecha bruta por sexo se explica por diferencias en conducta temprana, sustancias y contacto con el sistema penal, pero más de la mitad persiste después de controlar por todo lo observable. Una mujer comparable a un hombre en todas las demás dimensiones del modelo final tiene aproximadamente 8.5 puntos porcentuales menos de probabilidad de haber reportado una agresión.

Segundo, el coeficiente de **Raza: Black aumenta** entre el Modelo 3 y el Modelo 5, pasando de 0.042 a 0.106. Este patrón es importante: al controlar por habilidad cognitiva (Modelo 3) la brecha racial se reduce, pero al controlar por conducta temprana y arresto (Modelos 4–5) la brecha se amplía. Esto significa que, condicional a haber tenido conductas y arrestos similares, los jóvenes Black tienen una probabilidad mayor de reportar agresión que jóvenes no-Black/no-Hispanic comparables. La interpretación es coherente con literatura que sugiere que distintos grupos pueden estar expuestos a tasas distintas de contacto con instituciones formales por el mismo nivel de conducta subyacente.

Tercero, los coeficientes de los bloques de conducta y justicia son grandes y todos en la dirección esperada. Cada año adicional reportando pertenencia a una pandilla en la adolescencia temprana se asocia con 6.7 puntos porcentuales más de probabilidad de reportar agresión. Cada año reportando huida de casa, con 9.1 puntos porcentuales. Haber sido arrestado al menos una vez antes de los 18 años se asocia con 17.1 puntos porcentuales más de probabilidad de reportar agresión, después de controlar por todo lo demás.

Cuarto, las variables de consumo de sustancias muestran un patrón más débil. Sólo el tabaco resulta significativo (3.2 pp adicionales por año reportando consumo). Alcohol, marihuana y drogas duras no son significativos una vez que se controla por las conductas delictivas tempranas, lo que sugiere que parte del efecto bruto de estas sustancias opera a través de la conducta concurrente y no de manera independiente.

Por último, el coeficiente del puntaje ASVAB en el Modelo 5 es -0.0013 por punto. Como la variable se mide en percentiles 0–100, mover a un joven del percentil 10 al percentil 90 (es decir, 80 puntos) se asocia con una reducción esperada de $0.0013 \times 80 = 0.104$ puntos porcentuales en la probabilidad de reportar agresión. Esta magnitud sitúa a la habilidad cognitiva como un predictor cuantitativamente comparable a las brechas demográficas, aunque modesto frente al efecto de la conducta temprana y el arresto previo a los 18 años.

6.2 Comparación de ajuste

Table 7: Métricas de ajuste comparadas

Modelo	R^2	R^2 ajustada	AIC	BIC
Modelo 1: Demográfico	0.049	0.047	4727.5	4771.2
Modelo 2: + Familia y SES	0.066	0.063	4670.3	4757.7
Modelo 3: + Cognitivo	0.078	0.074	4625.0	4718.7
Modelo 4: + Conducta pasada	0.235	0.231	3925.9	4063.3
Modelo 5: + Justicia/Sustancias	0.265	0.260	3783.2	3951.9
Modelo 6: + Interacción sexo×raza	0.265	0.260	3785.9	3967.1

La Tabla 7 muestra que la mejora entre el Modelo 1 y el Modelo 5 es muy grande: la R^2 ajustada pasa de 0.047 a 0.260, un aumento absoluto de 21.3 puntos. El salto más espectacular ocurre entre el Modelo 3 y el Modelo 4 (del 7.4% al 23.1% de varianza explicada), lo que confirma que el bloque de conducta delictiva temprana es el que carga más peso explicativo. El bloque de justicia/sustancias añade 3.0 puntos adicionales y mejora todavía el AIC y el BIC.

El Modelo 6 no mejora ni R^2 ajustada ni AIC/BIC, y ambos términos de interacción son no significativos. La interpretación es directa: *en estos datos no hay evidencia de que la asociación entre sexo y agresión cambie de manera material según la raza/etnicidad*. Por la regla estándar de parsimonia, el modelo preferido es el **Modelo 5**, que tiene el AIC más bajo (3783.2) y el BIC más bajo (3951.9) entre todas las especificaciones consideradas.




Figure 5: R^2 ajustada por modelo. El bloque de conducta delictiva temprana (de M3 a M4) es el que aporta más capacidad explicativa.

6.3 ANOVA incremental

Table 8: ANOVA incremental entre modelos anidados

Transición	gl numerador	F incremental	p -valor	ΔR^2
M1 $\rightarrow$ M2 (+Familia y SES)	7	10.23	< 0.001	0.018
M2 $\rightarrow$ M3 (+Cognitivo)	1	47.40	< 0.001	0.012
M3 $\rightarrow$ M4 (+Conducta pasada)	7	111.36	< 0.001	0.157
M4 $\rightarrow$ M5 (+Justicia/Sustancias)	5	30.95	< 0.001	0.030
M5 $\rightarrow$ M6 (+Interacción sexo $\times$ raza)	2	0.64	0.526	0.000

La ANOVA incremental de la Tabla 8 cuantifica formalmente el aporte de cada bloque. Las primeras cuatro transiciones rechazan la hipótesis nula de igualdad de modelos con $p < 0.001$: cada bloque añade información estadísticamente significativa más allá de los anteriores. La transición M5 $\rightarrow$ M6 no rechaza ($p = 0.526$), lo que confirma cuantitativamente que la interacción sexo $\times$ raza no aporta poder explicativo adicional en esta cohorte. Este es un hallazgo informativo en sí mismo: la pregunta planteada en la introducción tiene respuesta empírica negativa, y la parsimonia recomienda quedarse con el Modelo 5.

7 Especificación del modelo base

A partir de la comparación anterior, tomamos el **Modelo 5** como modelo principal porque combina el mejor ajuste ($AIC = 3783.2$, $BIC = 3951.9$, R^2 ajustada = 0.260) con una interpretación económica clara. Su forma funcional es:

$$\begin{aligned} P(\text{EVER_ASSAULT}_i = 1) = & \beta_0 + \beta_1 \text{Mujer}_i + \beta_2 \text{Black}_i + \beta_3 \text{Hispanic}_i + \beta_4 \text{Mixed}_i \\ & + \beta_5 \text{EdadMadre}_i + \beta_6 \text{Hermanos}_i \\ & + \beta_7 \text{Fam1Padre}_i + \beta_8 \text{FamBioStep}_i + \beta_9 \text{FamOtra}_i \\ & + \beta_{10} \text{PadresHS}_i + \beta_{11} \text{PadresSC}_i + \beta_{12} \text{PadresCol}_i + \beta_{13} \text{Pobreza}_i \\ & + \beta_{14} \text{ASVAB}_i + \beta_{15...21} \text{Conducta14-17}_i + \beta_{22...25} \text{Sustancias14-17}_i \\ & + \beta_{26} \text{ArrestoPre18}_i + u_i. \end{aligned}$$

Los grupos de referencia del Modelo 5 son:

- Sexo: **Hombre**.
- Raza/etnicidad: **No-Black/No-Hispanic**.
- Estructura familiar: **Dos padres biológicos**.
- Educación de los padres: **Menos de preparatoria**.

8 Validación fuera de muestra (85/15)

Para revisar si el modelo final mantiene su desempeño fuera de la muestra de estimación, se dividió la base analítica en una partición aleatoria estratificada por la variable dependiente, con 85% para entrenamiento y 15% para prueba. La estratificación garantiza que la prevalencia de **EVER_ASSAULT** sea aproximadamente igual en ambos conjuntos.

Table 9: Partición entrenamiento–prueba

conjunto	n	proporción
Entrenamiento	3,242	85.0%
Prueba	573	15.0%

Table 10: Desempeño del Modelo 5 en entrenamiento y prueba

métrica	R^2	R^2 aj.	RMSE	MAE	Accuracy (0.5)	AUC
Entrenamiento (n=3,242)	0.256	0.250	0.397	0.322	0.774	0.807
Prueba (n=573)	0.309	—	0.382	0.308	0.794	0.837

La Tabla 10 muestra un desempeño estable. La R^2 en prueba (0.309) es ligeramente mayor que la R^2 en entrenamiento (0.256), lo que descarta sobreajuste. El RMSE de prueba (0.382) y el MAE (0.308) son consistentes con un LPM bien calibrado para una variable binaria con prevalencia 0.304.

El AUC en prueba alcanza 0.837: clasificando con umbral 0.5, el modelo predice correctamente el 79.4% de los respondientes del conjunto de prueba.




Figure 6: Probabilidad predicha contra valor observado de EVER_ASSAULT en el conjunto de prueba (se agrega *jitter* vertical para visualizar densidad).

Interpretación: Los respondientes que efectivamente reportaron agresión ($Y = 1$) tienden a recibir probabilidades predichas más altas que quienes no la reportaron ($Y = 0$). La separación no es perfecta (hay solapamiento importante en la región media), lo que es consistente con un AUC de 0.84: alto pero no cercano a 1.

9 Diagnóstico

Los diagnósticos de residuos se revisan sobre el Modelo 5 mediante los cuatro gráficos habituales: residuos contra ajustados, Q-Q plot, scale-location y residuos contra leverage. Adicionalmente se reportan el número de observaciones con leverage alto, las observaciones con Cook's distance elevada y la prueba de Breusch-Pagan para heterocedasticidad.

Table 11: Resumen de diagnósticos de residuos del Modelo 5

N	Parámetros	Umbral leverage $2p/n$	Obs. lev. alto	Obs. Cook alto	BP estadístico
3,815	27	0.0142	244 (6.4%)	159 (4.2%)	297.3 ($p < 0.001$)




Figure 7: Panel diagnóstico del Modelo 5: residuos vs ajustados, Q-Q plot, scale-location y residuos vs leverage.

Interpretación: El panel de la Figura 7 muestra el patrón característico de un Linear Probability Model. Los residuos contra ajustados se agrupan en dos bandas paralelas: la banda superior corresponde a observaciones con $Y = 1$ (residuo $= 1 - \hat{p}$) y la inferior a observaciones con $Y = 0$ (residuo $= -\hat{p}$). Esto no indica un problema del modelo sino una característica estructural del LPM: como la variable dependiente sólo toma dos valores, los residuos también lo hacen. El Q-Q plot se desvía de la diagonal en las colas por la misma razón. La prueba de Breusch-Pagan rechaza la homocedasticidad con $p < 0.001$, lo cual es esperable: en el LPM la varianza de u_i es $\hat{p}(1 - \hat{p})$ y depende explícitamente de las covariables. Por eso toda la inferencia del trabajo se realiza con errores estándar HC1.

En cuanto a leverage e influencia, el tamaño muestral hace que los umbrales mecánicos sean pequeños, por lo que no sorprende que aparezcan algunas observaciones señaladas. Aun así, las proporciones son moderadas: 6.4% supera el umbral de leverage ($2p/n = 0.0142$) y 4.2% supera el criterio de Cook ($4/n$). Existen, por tanto, observaciones potencialmente influyentes, pero no al grado de invalidar el patrón general del ajuste.

10 Conclusión

Los resultados del proyecto muestran que la probabilidad de reportar al menos una agresión física en la juventud no depende de una sola dimensión, sino de la suma estructurada de factores demográficos, familiares, cognitivos y, sobre todo, conductuales. El Modelo 5 alcanza una R^2 ajustada de 0.260 y un AUC fuera de muestra de 0.837, lo que representa una capacidad predictiva sustantiva para un fenómeno tan heterogéneo. La mejora más importante en ajuste proviene del bloque de conducta delictiva temprana, que por sí solo aumenta la varianza explicada en 15.7 puntos respecto al modelo cognitivo. El bloque de sustancias y justicia añade 3.0 puntos adicionales, principalmente a través de la variable de arresto antes de los 18 años, que sigue siendo el predictor individual más fuerte después de la propia historia conductual.

Las brechas demográficas no se anulan al controlar por conducta y arresto. La brecha por sexo se reduce cerca de la mitad pero sigue siendo de 8.5 puntos porcentuales en el modelo final; la brecha asociada a ser Black, lejos de desaparecer, se *amplía* al condicionar por conducta y arresto, llegando a 10.6 puntos porcentuales. Este último resultado es uno de los hallazgos más interesantes del trabajo: dos jóvenes con la misma historia conductual, el mismo perfil familiar y socioeconómico, la misma habilidad cognitiva y el mismo arresto previo a los 18 años, pero distinta raza, tienen probabilidades distintas de reportar agresión a lo largo de la juventud, con los jóvenes Black por arriba. La interpretación causal de esta diferencia requiere supuestos adicionales que están fuera del alcance del trabajo, pero es consistente con literatura que documenta exposición diferencial a contacto institucional y a violencia comunitaria.

La interacción entre sexo y raza no resultó significativa en estos datos. La asociación entre ser mujer y reportar agresión es similar entre los grupos raciales considerados, al menos dentro del poder estadístico de la muestra analítica. Este es un hallazgo informativo: no toda heterogeneidad esperada se confirma empíricamente, y reportarlo honestamente es importante para no sobreinterpretar el modelo.

Las implicaciones para política pública son claras y operacionalizables. Si el objetivo es reducir la prevalencia de violencia interpersonal en la juventud, la evidencia de este trabajo sugiere tres recomendaciones concretas. *Primero*, las intervenciones con mayor potencial son las que actúan *durante la adolescencia temprana* (14–17 años) sobre los marcadores conductuales identificados: pertenencia a pandillas, vandalismo, fugas del hogar y porte de armas. Programas como *Functional Family Therapy* o *Multisystemic Therapy*, que combinan trabajo con la familia, supervisión escolar y manejo de pares, abordan precisamente este conjunto de marcadores y han sido evaluados con asignación aleatoria en distintos contextos. *Segundo*, las políticas dirigidas exclusivamente a corregir factores cognitivos (programas escolares de aptitud) o estructurales (transferencias condicionadas a hogares en pobreza) probablemente sean insuficientes por sí solas: la asociación parcial entre ambos factores y la probabilidad de agresión existe pero es pequeña en comparación con la de los marcadores conductuales. Esto no implica que esos programas no deban implementarse —tienen otros beneficios— sino que enfocarlos como herramienta principal de reducción de violencia juvenil sobreestima su efecto. *Tercero*, el arresto antes de los 18 años marca un punto de inflexión particularmente importante: cada arresto adicional en ese tramo se asocia con 17 puntos porcentuales más de probabilidad de reportar agresión a lo largo de la juventud, después de controlar por todo lo demás. Esto justifica una atención preventiva intensiva en la fase de primer contacto con el sistema penal juvenil, donde intervenciones de *diversión* (*juvenile diversion programs*) pueden interrumpir trayectorias antes de que se consoliden. La brecha racial que persiste después de controlar por conducta y arresto, además, advierte que cualquier política focalizada debe monitorearse explícita-

mente por grupo demográfico para evitar amplificar inequidades preexistentes en el contacto con instituciones formales.

El ejercicio presenta limitaciones que conviene reconocer. Primero, el análisis es asociacional y no causal: los coeficientes describen relaciones parciales pero no identifican efectos causales estrictos. Segundo, la variable dependiente es autoreportada, con el subreporte característico de las encuestas sobre conducta delictiva. Tercero, la muestra analítica representa el 42.5% de la cohorte original; la atrición proviene principalmente de `POVRATIO97` y `ASVAB_SCORE`, lo que puede introducir cierta selectividad. Cuarto, el LPM es eficiente y transparente pero produce predicciones que pueden caer fuera de $[0, 1]$. Como trabajo futuro, valdría la pena replicar el ejercicio con logit y probit para verificar robustez, incorporar pesos muestrales del NLSY97 para reproducir parámetros poblacionales, y explorar la heterogeneidad por cohorte de edad ajustando modelos separados para los tramos 14–17 y 18–25.

11 Referencias

- Bureau of Justice Statistics. *Recidivism in the National Longitudinal Survey of Youth 1997 – Standalone Data (Rounds 1 to 13)*. ICPSR 34562, v.1, 2014. DOI: 10.3886/ICPSR34562.v1.
- Bureau of Labor Statistics. *National Longitudinal Survey of Youth 1997 (NLSY97) Cohort: User’s Guide*. U.S. Department of Labor.
- White, H. (1980). A heteroskedasticity-consistent covariance matrix estimator and a direct test for heteroskedasticity. *Econometrica*, 48(4), 817–838.
- Wooldridge, J. M. (2010). *Econometric Analysis of Cross Section and Panel Data*, 2nd ed., MIT Press.
- Material del curso Estadística Aplicada II, ITAM.